



$x_{1,1}$



$x_{1,2}$



$x_{2,1}$



$x_{2,2}$

# Tecniche e applicazioni biometriche

Fabio Scotti

[fabio.scotti@unimi.it](mailto:fabio.scotti@unimi.it)


Università degli Studi di Milano

# Modelli statistici per sistemi biometrici


## Parte 2

# Classificatore biometrico

- Multiclasse = Identificatore




- Binario = Autenticatore





Sistema  
biometrico  
=  
classificatore  
 $P(\text{errore}) = p$

# Il sistema biometrico visto come classificatore



# SB = classif.




# Esperimenti di Bernoulli

- Questi eventi sono **esperimenti/prove di Bernoulli**
  - “Dado=6”,
  - “ScommessaDadoPersa”,
  - “Genere non correttamente individuato”
- Ad ogni singola prova si hanno solo due esiti possibili
  - ‘successo’ (1)
  - ‘insuccesso’ (0)
- La probabilità  **$p$**  dell’evento ‘successo’ è costante;
- I risultati delle prove sono **indipendenti**.

# Come modelliamo gli errori?

- Date due impronte generiche (genuini e/o impostori) il SB in autenticazione mostra un tasso medio di errore stimabile e fissato  $p$



- l'evento che il SB sbaglia una autenticazione è un esperimento/prova di Bernoulli
- Un SB che venga usato in identificazione (**1:N**) si può modellizzare come un **N prove di Bernoulli**, ovvero un processo di Bernoulli

# Distribuzione degli errori

Similmente al problema famoso del «mezzo pollo statistico a testa» dire  $p(\text{errore})=0,05$  (5%) può voler dire cose molto diverse per gli utenti



- 90 persone con errore 0% e 10 con errore 50%
- 50 persone con errore 0% e 50 con errore 10%
- 30 persone con errore 0% e 70 con errore 7%

Dipende da quante pecore, capre, agnelli e lupi abbiamo negli utenti  
(vedere lez. doddington zoo)



# Distribuzione di Bernoulli



La distribuzione di Bernoulli  $\mathcal{B}(p)$  di parametro  $p \in [0, 1]$  è

$$P(1) = p,$$

$$P(0) = q = 1 - p,$$

ossia

$$P(X = i) = p^i (1 - p)^{1-i}.$$

Il valore atteso è

$$E(x) = p^1 (1 - p)^{1-1} = p,$$

e la varianza è

$$\text{Var}(X) = p(1 - p) = qp.$$

Es:

probabilità di errore  
di autenticazione  $p = 0,01$

Varianza( $p$ ) = 0,0099

Std( $p$ ) = 0,099

$\mathcal{B}(n, p)$ 

# SB $\leftrightarrow$ Proc. Bernoulli

DESCRIVE ERRORI in  
IDENTIFICAZIONE /  
N utenti AUTENTICATI

- Variabile aleatoria X può valere
  - $X=1$  (Successo) oppure  $X=0$  (fallimento)
  - Probabilità di successo è p; Probabilità di fallimento è  $q=1-p$
  - Per noi  $X=1$  è un errore sul singolo test del SB



- Il numero di "successi« (errori del SB) dopo n prove è dato dalla variabile aleatoria  $S_n$

$$S_n = X_1 + X_2 + \dots + X_n$$

- La probabilità di avere k errori su n prove è (con  $q=1-p$ )

Binomiale

$$P(S_n = k) = \binom{n}{k} p^k q^{n-k} \quad \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

- Ovvero al numero di sequenze di k successi e n-k fallimenti, moltiplicato per la probabilità che una qualunque di queste si verifichi
- Es: Se il sistema ha  $p=1e-2$ , la Prob. di avere 1 errore su 1000 prove si trova applicando la formula con  $n=1000$ ,  $k=1$

# La roulette russa

## → sistema biometrico in ident.


- Roulette russa

- $p \text{ errore} = 1/6$  (con rotazione tamburo)
- $P(N \text{ tentativi}) = \dots$



- Sistema biometrico in identificazione

- $p$  = prob. errore singola autent.
- $N$  = numero utenti nel DB




# Binomiale (distribuzione errori SB)

$$P(S_n = k) = \binom{n}{k} p^k q^{n-k}$$

Facciamo degli esempi per capire meglio come si usa la distribuzione

$\mathcal{B}(n, p)$




Non è un  
distribuzione  
continua!

# Binomiale $p=0.01$

$$P(S_n = k) = \binom{n}{k} p^k q^{n-k}$$

$$P(S_n = k) \quad \mathcal{B}(n, p) \quad \mathcal{B}(20, 0.01)$$



```
>> k = 0:20;  
>> y = binopdf(k,20,0.01);  
>> plot(k,y,'+')
```

Se l'errore è basso  
la forma cambia  
completamente  
e cade subito verso zero

$P(\text{nessun errore su 20 test}) = \mathcal{B}(20, 0.01) \text{ con } k=0$   
 $0.99^{20} = \mathbf{0,817}$

# Cosa stimare?

Se ho un Sistema Biometrico (SB) con tasso di errore  $p$  (quindi dato  $p$ ) in una generica **autenticazione** ...

- Quanto può cambiare  $p$  se rifaccio l'esperimento con gli stessi volontari?
- Quale è il tasso di errore  $p_2$  se uso SB per fare identificazione con 100 persone (Dipartimento)?
- Quale è il tasso di errore  $p_3$  se uso SB per fare identificazione con 1.000.000 di persone?
- Come posso stimare il tasso di errore  $p$  iniziale?
- Quante persone  $N$  mi servono per avere una buona stima di  $p$ ?
- Come si *definisce correttamente* una buona stima di  $p$ ?

# Regola dei 3

*“Quale è il tasso di errore più basso  $p$  che può essere stimato con un esperimento di comparazione di  $N$  campioni indipendenti?”*


**Il tasso di errore  $p$  per il quale si ha la probabilità di ZERO errori in  $N$  prove è circa  $p \approx 3/N$ , per un intervallo di confidenza del 95%.**

- Altro modo di leggere la cosa: se abbiamo un sistema che commette ZERO errori su  $N$  prove non dobbiamo pensare di avere un sistema con  $p=0$ , ma con il 95% di confidenza abbiamo un sistema che ha  $p \approx 3/N$ .

Esempio:

- Se faccio 300 prove con campioni indipendenti e ho ZERO errori, allora posso dire che con confidenza del 95% il mio sistema ha un tasso di errore stimato del  $p \approx 3/N = 3/300 = 1\%$

# Estensione della regola dei 3



Se il sistema commette 5 errori su N prove indipendenti

# Errori da Verification a Identification

“Quanto aumentano gli errori se uso  
un sistema di *Verifica* (FMR, FNMR)  
in modalità di *Identificazione* (FMR<sub>N</sub>, FNMR<sub>N</sub>)?”


- Usando delle ipotesi semplificative (es. Campioni indipendenti, non ci sono meccanismi di indicizzazione del DB, un solo campione per utente) è possibile mostrare in prima approssimazione che ...
- $FNMR_N = FNMR$   
(I tassi di errore per i **genuini** non cambiano)
- $FMR_N = 1 - (1 - FMR)^N$   
Ovvero = 1- (la probabilità che **non** ci sia un False match su tutti i campioni confrontati N)
  - Con FMR “piccolo” l’espressione diventa  **$FMR_N = N * FMR$**   
Ovvero l’errore di False Match aumenta linearmente con le dimensioni del DB.

# La regola dei 30

- La regola dei 30 è usata per determinare la larghezza del campione biometrico in questo modo:  
“Per essere sicuro con intervallo di conf. del 90% che il tasso di errore **vero** sia tra il  $\pm 30\%$  del tasso di errore **osservato** ci devono essere almeno 30 errori”.
- ES:  
Se abbiamo 30 falsi NON-match in 3000 comparazioni di genuini indipendenti, possiamo dire (con interv. di conf. del 90%) che l'errore vero sta tra 0.7% e 1.3%.

# Abbiamo visto molti argomenti teorici utili nei progetti biometrici

- *Non-idealità del mondo reale*
- *Non indipendenza dei campioni*
- *Doddington's Zoo e casi singolari*
- *Problema della dimensione del test*
- *Regola del 3 & Regola del 30*
- *Intervalli di confidenza*



# L10



## Outline


1. Dispensa Best Practices

2. Metodo per la progettazione e misura delle performance in caso di modelli di machine learning

# Altri errori: FTE e FTA

**Failure to enrol rate:** The “failure to enrol” rate is the expected proportion of the population for whom the system is unable to generate repeatable templates. This will include those unable to present the required biometric feature, those unable to produce an image of sufficient quality at enrolment, and those who cannot reliably match their template in attempts to confirm the enrolment is usable. The failure to enrol rate will depend on the enrolment policy. For example in the case of failure, enrolment might be re-attempted at a later date.

**Failure to acquire rate:** The “failure to acquire” rate is defined as the expected proportion of transactions for which the system is unable to capture or locate an image or signal of sufficient quality. The failure to acquire rate may depend on adjustable thresholds for image or signal quality.



# Zero-Effort attempts

**Zero-effort attempts:** An impostor attempt is classed as “zero-effort” if the individual submits their own biometric feature as if they were attempting successful verification against their own template. In the case of dynamic signature verification, an impostor would therefore sign his or her own signature in a zero-effort attempt. In such cases, where impostors may easily imitate aspects of the required biometric, a second impostor measure based on “active impostor attempts” may be required. However, defining the methods or level of skill to be used in active impostor attempts is outside the scope of this document.



- Presentation attack

Vanno previsti e dettagliati  
VEDREMO QUESTI ARGOMENTI  
NELLA PARTE FINALE DEL CORSO



DATA REPORTING

# MEMO: Strategie di valutazione



Nella dispensa si fa spesso riferimento a questi 3 scenari

# Dispensa

## Best Practices in Testing and Reporting Performance of Biometric Devices

La dispensa è materia di esame e deve essere studiata in quanto riassume bene molti argomenti visti nel corso (si SEZ. 1,2,3,4,5, no SEZ. 6, si SEZ. 7,8).

Seguono una selezione di punti della dispensa per una discussione

# Parti molto utili

|                     |                                                                                    |                      |
|---------------------|------------------------------------------------------------------------------------|----------------------|
| <b>1</b>            | <b>Introduction.....</b>                                                           | <b>1</b>             |
| <b>2</b>            | <b>Definitions.....</b>                                                            | <b>2</b>             |
| 2.1                 | Components of a biometric system.....                                              | 2                    |
| 2.2                 | Types of evaluation.....                                                           | 3                    |
| 2.3                 | Identity claims: genuine & impostor, positive & negative, explicit & implicit..... | 4                    |
| 2.4                 | Performance measures.....                                                          | 4                    |
| 2.4.1               | Decision error rates.....                                                          | 4                    |
| 2.4.2               | Matching errors.....                                                               | 5                    |
| 2.4.3               | Image acquisition errors.....                                                      | 6                    |
| 2.4.4               | Binning algorithm performance.....                                                 | 6                    |
| 2.5                 | Genuine and Impostor attempts.....                                                 | 6                    |
| 2.6                 | Online and offline generation of matching scores.....                              | 7                    |
| 2.7                 | DET & ROC curves.....                                                              | 7                    |
| 2.8                 | Statistical terms.....                                                             | 8                    |
| <b>3</b>            | <b>Planning the evaluation.....</b>                                                | <b>9</b>             |
| 3.1                 | Determine information about the system etc.....                                    | 9                    |
| 3.2                 | Controlling factors that influence performance.....                                | 9                    |
| 3.3                 | Volunteer selection.....                                                           | 10                   |
| 3.4                 | Test size.....                                                                     | 11                   |
| 3.4.1               | Rule of 3.....                                                                     | 11                   |
| 3.4.2               | Rule of 30.....                                                                    | 11                   |
| 3.4.3               | Collecting multiple transactions per person.....                                   | 12                   |
| 3.4.4               | Recommendations on test size.....                                                  | 12                   |
| 3.5                 | Multiple tests.....                                                                | 13                   |
| <b>4</b>            | <b>Data collection.....</b>                                                        | <b>13</b>            |
| 4.1                 | Avoidance of data collection errors.....                                           | 13                   |
| 4.2                 | Data and details collected.....                                                    | 14                   |
| 4.3                 | Enrolment and test transactions.....                                               | 15                   |
| 4.4                 | Genuine transactions.....                                                          | 16                   |
| 4.5                 | Impostor transactions.....                                                         | 18                   |
| 4.5.1               | Online collection of impostor transactions.....                                    | 18                   |
| 4.5.2               | Offline generation of impostor transactions.....                                   | 19                   |
| 4.5.3               | Intra-individual comparisons.....                                                  | 20                   |
| <b>5</b>            | <b>Analysis.....</b>                                                               | <b>20</b>            |
| 5.1                 | Failure to enrol rate; failure to acquire rate.....                                | 20                   |
| 5.2                 | Detection error trade-off curves.....                                              | 20                   |
| 5.3                 | Binning error versus penetration rate curve.....                                   | 21                   |
| <del><b>6</b></del> | <del><b>Uncertainty of estimates.....</b></del>                                    | <del><b>22</b></del> |
| <del>6.1</del>      | <del>Estimates for variance of performance measures.....</del>                     | <del>22</del>        |
| <del>6.2</del>      | <del>Variance of observed false non-match rate.....</del>                          | <del>22</del>        |
| <del>6.3</del>      | <del>Variance of observed false match rate.....</del>                              | <del>23</del>        |
| <del>6.4</del>      | <del>Estimating confidence intervals.....</del>                                    | <del>24</del>        |
| <b>7</b>            | <b>Reporting performance results.....</b>                                          | <b>25</b>            |
| <b>8</b>            | <b>Conclusions.....</b>                                                            | <b>25</b>            |

# REPORTING PERFORMANCE RESULTS (1)


Esaminiamo i dettagli richiesti per una completa descrizione del sistema

- a. Details of the system tested. This should include more than just the biometric component, as factors such as the user interface will influence performance too;
- b. The type of evaluation:
  - Technology evaluation:** Details of the sample databases used;
  - Scenario evaluation:** Details of the test scenario;
  - Operational evaluation:** Details of the operational application;
- c. Size of evaluation:
  - Number of volunteers;
  - (Number of fingers/hands/eyes/etc. enrolled by each volunteer);
  - Number of visits made by volunteer;
  - Number of transactions per volunteer (or volunteer finger, etc.) at each visit;
- d. Demographics of the volunteer crew;
- e. Details of the test environment;
- f. Time separation between enrolments and test transactions;
- g. Quality and decision thresholds used during data collection;
- h. Details of which factors potentially affecting performance were controlled, and how these were controlled (see Appendix A);
- i. Details of the test procedure, e.g., policies for determining enrolment failures, etc.;
- j. Details of abnormal cases, and data excluded from analysis;
- k. Estimated uncertainties (if calculated);
- l. Deviations from these Best Practices should also be explained. Sometimes it will be necessary to compromise one aspect, in order to achieve another. (E.g. randomising the order of using fingers on a fingerprint device might lead to user confusion and a higher number of labelling errors.)

# REPORTING PERFORMANCE RESULTS (1)

a.

Details of the system tested. This should include more than just the biometric component, as factors such as the user interface will influence performance too;




# REPORTING PERFORMANCE RESULTS (1)

- a. Details of the system tested. This should include more than just the biometric component, as factors such as the user interface will influence performance too;
- b. The type of evaluation:
  - Technology evaluation:** Details of the sample databases used;
  - Scenario evaluation:** Details of the test scenario;
  - Operational evaluation:** Details of the operational application;
- c. Size of evaluation:
  - Number of volunteers
  - (Number of fingers/hands)
  - Number of visits made
  - Number of transactions
- d. Demographics of the volunteers
- e. Details of the test environment

## Strategie di valutazione

[ISO/IEC 19795 Biometric Performance Testing and Reporting](#)



DATA REPORTING

# REPORTING PERFORMANCE RESULTS (1)

- a. Details of the system tested. This should include more than just the biometric component, as factors such as the user interface will influence performance too;
- b. The type of evaluation:
  - Technology evaluation:** Details of the sample databases used;
  - Scenario evaluation:** Details of the test scenario;
  - Operational evaluation:** Details of the operational application;
- c. Size of evaluation:
  - Number of volunteers;
  - (Number of fingers/hands/eyes/etc. enrolled by each volunteer);
  - Number of visits made by volunteer;
  - Number of transactions per volunteer (or volunteer finger, etc.) at each visit;
- d. Demographics of the volunteer crew;
- e. Details of the test environment;



# REPORTING PERFORMANCE RESULTS (1)

- a. Details of the system tested. This should include more than just the biometric component, as factors such as the user interface will influence performance too;
- b. The type of evaluation:
  - Technology evaluation:** Details of the sample databases used;
  - Scenario evaluation:** Details of the test scenario;
  - Operational evaluation:** Details of the operational application;
- c. Size of evaluation:
  - Number of volunteers;
  - (Number of fingers/hands/eyes/etc. enrolled by each volunteer);
  - Number of visits made by volunteer;
  - Number of transactions per volunteer (or volunteer finger, etc.) at each visit;
- d. Demographics of the volunteer crew;
- e. Details of the test environment,



# REPORTING PERFORMANCE RESULTS (1)

- a. Details of the system tested. This should include more than just the biometric component, as factors such as the user interface will influence performance too;
- b. The type of evaluation:
  - Technology evaluation:** Details of the sample databases used;
  - Scenario evaluation:** Details of the test scenario;
  - Operational evaluation:** Details of the operational application;
- c. Size of evaluation:
  - Number of volunteers;
  - (Number of fingers/hands/eyes/etc. enrolled by each volunteer);
  - Number of visits made by volunteer;
  - Number of transactions per volunteer (or volunteer finger, etc.) at each visit;
- d. Demographics of the volunteer crew;
- e. Details of the test environment;



# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione

f.

Time separation between enrolments and test transactions;



12h





February 23rd, 1987, 88, 89, 90, 91, 92, 93, 94, 95, 96, 97, 98, 99, 00, 01, 02, 03, 04, 05, 06, 07

30 anni

# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione

- f. Time separation between enrolments and test transactions;  
g. Quality and decision thresholds used during data collection;



# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione

- f. Time separation between enrolments and test transactions;
- g. Quality and decision thresholds used during data collection;
- h. Details of which factors potentially affecting performance were controlled, and how these were controlled (see Appendix A);
- i. Details of the test procedure, e.g., policies for determining enrolment failures, etc.;
- j. Details of abnormal cases, and data excluded from analysis;
- k. Estimated uncertainties (if calculated);
- l. Deviations from these Best Practices should also be explained. Sometimes it will be necessary to compromise one aspect, in order to achieve another. (E.g. randomising the order of using fingers on a fingerprint device might lead to user confusion and a higher number of labelling errors.)

Esempio

Creare un test troppo favorevole, o in condizioni troppo diverse

# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione

- f. Time separation between enrolments and test transactions;
- g. Quality and decision thresholds used during data collection;
- h. Details of which factors potentially affecting performance were controlled, and how these were controlled (see Appendix A);
- i. Details of the test procedure, e.g., policies for determining enrolment failures, etc.;
- j. Details of abnormal cases, and data excluded from analysis;
- k. Estimated uncertainties (if calculated);
- l. Deviations from these Best Practices should also be explained. Sometimes it will be necessary to compromise one aspect, in order to achieve another. (E.g. randomising the order of using fingers on a fingerprint device might lead to user confusion and a higher number of labelling errors.)

Policy: se l'utente non capisce bene il protocollo → lo escludiamo...  
(ok ma poi come stiamo questi utenti in deployment?)

# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione


- f. Time separation between enrolments and test transactions;
- g. Quality and decision thresholds used during data collection;
- h. Details of which factors potentially affecting performance were controlled, and how these were controlled (see Appendix A);
- i. Details of the test procedure, e.g. policies for determining enrolment failures, etc.;
- j. Details of abnormal cases, and data excluded from analysis;
- k. Estimated uncertainties (if calculated);
- l. Deviations from these Best Practices should also be explained. Sometimes it will be necessary to compromise one aspect, in order to achieve another. (E.g. randomising the order of using fingers on a fingerprint device might lead to user confusion and a higher number of labelling errors.)

Esempi:  
Malattie, Tatuaggi e  
protesi estetiche estreme

# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione

- f. Time separation between enrolments and test transactions;
- g. Quality and decision thresholds used during data collection;
- h. Details of which factors potentially affecting performance were controlled, and how these were controlled (see Appendix A);
- i. Details of the test procedure, e.g., policies for determining enrolment failures, etc.;
- j. Details of abnormal cases, and data excluded from analysis;
- k. **Estimated uncertainties (if calculated);**
- l. Deviations from these Best Practices should be necessary to compromise one aspect, in the order of using fingers on a fingerprint higher number of labelling errors.)




# REPORTING PERFORMANCE RESULTS (2)

Sono dati molto importanti da comunicare nella documentazione

- f.* Time separation between enrolments and test transactions;
- g.* Quality and decision thresholds used during data collection;
- h.* Details of which factors potentially affecting performance were controlled, and how these were controlled (see Appendix A);
- i.* Details of the test procedure, e.g., policies for determining enrolment failures, etc.;
- j.* Details of abnormal cases, and data excluded from analysis;
- k.* Estimated uncertainties (if calculated);
- l.* Deviations from these Best Practices should also be explained. Sometimes it will be necessary to compromise one aspect, in order to achieve another. (E.g. randomising the order of using fingers on a fingerprint device might lead to user confusion and a higher number of labelling errors.)

# Procedure in caso di apprendimento (uso di Machine Learning)


Come valutare correttamente i  
parametri quando in un  
sistema è presente  
apprendimento



Esamineremo aspetti  
di apprendimento automatico  
nella biometria





Conoscenza  
nei sistemi  
biometrici

Aspetti  
multi-  
disciplinari



# Flusso di lavoro

Applicare le opportune procedure di training!




$p$

# Comprare un sistema «of the shelf» con ML

Si possono avere diversi casi


- Avere già **p**
- Doverlo allenare/fine tuning
- Scegliere solo **T**
- Fidarsi completamente dei dati riportati sui datasheet (!?)

Anche solo usare un diverso localizzatore di volti cambia tutte le prestazioni



# Come modelliamo gli errori se il classificatore apprende?

- Se facciamo il classificatore con un classificatore che apprende da esempi (induttivo) come una rete neurale per esempio come possiamo stimare la sua accuratezza?




# Problemi e soluzioni quando si usa Machine Learning

La gestione dei dati quando si usano metodi di machine learning diventa **critica**!

Si introducono problemi come **l'overfitting, underfitting, bias e leakage delle informazioni**

Soluzioni:

- Corretta **gestione** del dataset
- Creazione ed uso di opportune **Partizioni**
- Tecniche di **Cross Validation**





# Quando creiamo più soluzioni con il machine learning, quale scegliamo?

Potremmo aver creato diverse reti neurali o modelli di machine learning. Ora quale scegliamo?

Usiamo dei metodi statistici per compararli

- **Test Parametrici** e **condizioni** per il loro uso corretto
- Test non-parametrici per la
  - ❑ **comparazione di due modelli**/algoritmo con dataset multipli
  - ❑ **comparazioni multiple** fra più di due modelli/algoritmi



# Data Sets e gestione delle Partizioni

Quali sono le tecniche migliori per partizionare i dati per non avere overfitting dei dati e poter mandare in deployment un sistema biometrico basato su ML affidabile?

# Data Sets e Partizioni

- Lo scopo finale della maggior parte dei processi di Machine Learning è quello di essere usato per risolvere **problemi reali**
  - Testare una tecnica in ogni problema/condizione non è fattibile
  - Una procedura comune consiste nel valutare la tecnica di ML in un **set di problemi standard** (data sets) pubblici (benchmarks)

Nota: non è attualmente possibile realizzare un sistema di pattern recognition che riconosca la presenza di un volto in ogni tipo di immagine!

→ Dobbiamo crearlo specifico per la nostra applicazione



Per esempio qui abbiamo le maschere!

# Creazione del Data Set

- I dataset di “benchmark” sono usati con questo scopo:

**Valutare le performance di un dato modello su un set di problemi noti e standard**

- Tuttavia i dati devono essere usati correttamente per evitare **bias (polarizzazioni) nei risultati!**



Come scegliere una guida?



A) specializzata

Solo dati molto simili alla mia applicazione?



B) Generica?

Dati da contesti molto diversi dalla mia applicazione?




# Usare tutti i dati per train? NO!

- Se usando tecniche di Machine Learning il dataset completo viene usato sia per costruire il modello sia per validarlo, **non abbiamo informazioni su come si comporterà il modello su dati nuovi e mai visti....**
- In particolare, **due problemi principali** possono nascere
  - **Underfitting**: accade quando il modello non riesce ad apprendere la complessità dei dati e soffre di errori elevati sia in training che in validazione
  - **Overfitting**: accade quando il modello apprende anche il rumore sovrapposto ai dati o impara a memoria senza capacità di generalizzazione, presentando bassi errori in apprendimento, ma alti in validazione con dati sconosciuti.


# Soluzione: Data Set Partitioning

Usare due insieme di dati (un insieme di dati di **train** e un insieme di dati mai usati in train per fare un test di **validazione**) ci permettere di identificare il comportamento dannoso chiamato di **overfitting**.

L'esperimento rappresentato consiste nel rifare l'intero apprendimento di reti aumentando il numero di neuroni, cosa succede all'errore sul train set e sul test set?




# Underfitting e Overfitting 1D




Underfitted

Questo modello lineare non è sufficiente per imparare la complessità di questi dati



Good Fit/Robust


Questo modello polinomiale sembra avere i giusti gradi di libertà per apprendere l'andamento dei dati senza imparare anche il rumore



Overfitted


Questo modello polinomiale con troppi gradi di libertà ha imparato il rumore sui dati

# Underfitting e Overfitting 2D




**Under-fitting**

(too simple to  
explain the  
variance)




**Appropriate-fitting**



**Over-fitting**

(forcefitting -- too  
good to be true)

# Overfitting 2D (bis)





# Se non faccio bene Data Set Partitioning

Warning !  
Molto molto  
importante

## Underfitting



- Se usiamo anche tutti i dati per fare training ma abbiamo elevato errore (bassa accuratezza)
- Il modello non è adeguato ai dati
- Mancano dati di apprendimento che possano spiegare la complessità del fenomeno.
  - Mancano dati in una parte del dominio
  - Mancano variabili importanti
  - ...




Warning !  
Molto molto  
importante

# Se non faccio bene Data Set Partitioning



## Overfitting

- Per evitare di continuare ad aggiustare i pesi del mello per fittare sempre di più i dati  
→ adottato una condizione di **early stopping** per fermare l'apprendimento
  - Se non **tengo da parte dei casi mai visti**, non posso rendermi conto che sono in overfitting !
  - Tipicamente **impara anche il rumore** nei dati



Warning !  
Molto molto  
importante


# Data Set Partitioning

- Necessario per :
  - Controllare la performance del modello
  - Evitare l'overfitting
  - Produrre una stima della qualità di generalizzazione del modello ottenuto
- **Sono disponibili più metodi di partizione!**
  - Come creare le partizioni è un **argomento fondamentale** che influenzerà molto le performance dei modelli generati
  - **Se sbaglio** a creare le partizioni del dataset, sicuramente avrò un comportamento del **modello incompleto o polarizzato**




# Approccio generale: CrossValidazione (CV)

A Cross-validation



B Prediction testing



$e_i$  = errore sul singolo gruppo

# Quale è il concetto principale della Cross Validazione?


- La cross-validazione è una tecnica utilizzata per valutare la **generalizzazione** di un modello su un set di dati indipendente.
  - Serve a **stimare quanto bene il modello addestrato sarà in grado di fare previsioni su nuovi dati** non visti durante la fase di addestramento
- In pratica come si fa?  
Dovremo generare tanti modelli con dati leggermente diversi e guardare fra di loro quanto differisce l'errore.
  - **La teoria dice che questa è una la migliore simulazione possibile da applicare con i dati a disposizione per simulare il mondo reale!**

# $k$ -Fold Cross Validation ( $k$ -FCV)

# Data Set Partitioning: $k$ -FCV

- Il più comune metodo di cross validazione si chiama  **$k$ -Fold** Cross Validation ( $k$ -FCV):
  1. Nel  $k$ -FCV, il dataset originale è diviso casualmente in  $k$  partizioni della stessa dimensione
  2. Delle  $k$  partizioni, 1 è tenuta per verificare il modello, e le rimanenti  $k - 1$  sono usate per allenare il modello
  3. Il processo è ripetuto  $k$  volte usando turno le  $k$  partizioni per validare il modello stando attenti a mai usarle in apprendimento ad ogni giro

# k-FCV



# Dagli errori → media, std

Avendo fatto  $k$  test separati, possono studiare gli errori dei singoli gruppi-partizioni usati nei  $k$  apprendimenti

$$\{e_1, e_2, \dots, e_k\}$$


Posso capire già molte cose e sicuramente devo considerare

- Media\_Errore =  $\text{mean}(\{e_1, e_2, \dots, e_k\})$
- Std\_Errore =  $\text{std}(\{e_1, e_2, \dots, e_k\})$
- Max\_Errore =  $\text{max}(\{e_1, e_2, \dots, e_k\})$

Per esempio posso stimare l'errore dello stimatore

$p_{\text{stimato}} \rightarrow \text{media} = 3,3\% ; \text{std} = 1\%$

Stima  
dello  
stimatore





3,3% +- 1%

# k-FCV: che valore scelgo per $k$ ?

- Di solito si usano valori di  $k$  fra 5 e 10-12
- **Attenzione:  $k$  deve essere regolato** per evitare di generale delle partizioni troppo piccolo e non correttamente popolate di tutte le casistiche che porterebbero a generalizzazioni errate
- Regole di buon senso: se il dataset è
  - esteso di solito si usa la 10-FCV
  - piccolo si usa spesso la 5-FCV

# Stratified k-FCV

- Il normale  $k$ -FCV può portare a sbilanciare la proporzione delle classi nelle partizioni di validazione  
→ stime non ottimali
- Per evitare questo di solito si usa il **stratified  $k$ -FCV**
  - Non si usa una semplice indirizzazione casuale
  - Vengono messi in ogni partizione lo stesso numero di campioni di ogni classe per **mantenere la distribuzione delle classi in ogni partizione**




Esempio di come si dividono i dati della classe marrone nelle 4 partizioni


# Stratified k-FCV

Esempio con  $k=5$

Stratified K-Fold  
Cross Validation  
( $K=5$ )



Total  
Class Distributions




Notare come la  
distribuzione delle classi  
(F e M) venga mantenuta  
in ogni partizione delle 5

Stessa cosa vale per

- Diverse età
- Genere
- Razza
- Background
- Ecc..

ESEMPIO 2  
QUESTE FETTE NON  
VANNO BENE COME  
STRATIFIED K-FCV!






# 5×2 Cross Validation (5×2 CV)

# Data Set Partitioning: $5 \times 2$ CV (5 times 2-fold Crossvalidation)

- Il dataset viene diviso randomicamente in 2 partizioni A and B
  1. Si applica una kFCV con  $k=2$ 
    1. Il modello viene prima allenato con A e testato con B
    2. Il modello viene ora allenato con B e testato con A
    3. Si calcola l'errore medio delle due prove e
  2. Ripetere 1) 5 volte
  3. Si aggregano gli errori ad ogni giro
$$\{e_1, e_2, \dots, e_5\}$$
  4. Si calcolano media e deviazione standard errori

# Data Set Partitioning: 5×2 CV




# Ok, ma quale modello mando in deployment?

Che tu abbia eseguito una delle tecniche k-FCV, Stratified k-FCV, 5x2CV, o altre eventuali, hai generato diversi modelli e ognuno dei quali ha avuto un errore sul suo insieme di test

- Quale modello scelgo per il deployment?
  - OPZIONE **A**: rialleno il modello su tutti i dati, ma comunico i risultati del CV
  - OPZIONE **B**: scegli quello con errore più basso in test e validazione, oppure il modello con meno entropia nei pesi  $\{e_1, e_2, \dots, e_k\}$
  - OPZIONE **C**: mi tengo un test set aggiuntivo  
(vedi prossima slide)

Ok, ma quale modello mando in deployment?  
**Tenere una valutazione finale!**

Altro modo (corretto) di procedere



# Leave one out! (LOO)



SAMPLE




# Data Set Partitioning: *Leave One Out*

- In casi estremi si ha che  $k$ -FCV  $\rightarrow$   *$k$  è uguale al numero di esempi nel dataset*
- Ad ogni giro della validazione UNO SOLO campione viene usato come test e tutti gli altri sono usati per fare apprendimento



# Data Set Partitioning: *Leave one out*



# Leave one PERSON out! (LOPO)




PERSON



# Rivediamo il contesto


- Abbiamo un sistema biometrico (per esempio una rete neurale) che impara ad autenticare le persone da migliaia di esempi
- Si tratta in ogni caso di un classificatore (out=1 genuino, out=0 impostore) con una sua probabilità di errore  $p$



# Apprendimento e CrossValidation semplice... No good

Feature facciali  
o misura il colore  
dei capelli  
per dire se gen.?

Avere le stesse  
persone in train e  
validazione può  
semplificare troppo  
il modello



# Leave One Person Out (LOPO)


- L'apprendimento di una rete neurale a molti livelli e/o neuroni è tale da imparare a memoria i soggetti NON dalla caratteristica biometrica che vogliamo impiegare
  - Impara il colore della pelle, la presenza di barba ma non i tratti del volto
  - L'accuratezza può arrivare a EER=0 fittiziamente!

## SOLUZIONE

→ teniamo un gruppo di persone per fare autenticazione solo in validazione e MAI viste in allenamento

# LOPO L(NP)O

Ora è più difficile che impari  
a riconoscere solo  
dal colore dei capelli!



# Nuove Tecniche

## Modelli multimodali, Zero shot, Frewshot

- Nelle prossime lezioni introdurremo **l'uso di modelli linguistici e multimodali** applicato alla biometria avanzata.
  - **modelli multimodali** (immagine, video, audio, testo)
  - **modelli foundation e linguistici**
  - **approcci zero-shot e few-shot**
- Questi approcci **rompono** molte delle ipotesi viste finora.  
In particolare:
  - **non esiste più un dataset etichettato classico**
  - **non esiste una separazione chiara training / test**
  - **la cross-validation tradizionale non è direttamente applicabile per**
    - La valutazione delle prestazioni,
    - La stima dell'errore,
    - La misura della confidenza
- Vedremo nelle prossime lezioni come
  - misurare l'errore
  - valutare la confidenza

>> vedi in questa immagine una potenziale situazione pericolosa, se sì quale?

Sì, nell'immagine vedo diverse situazioni potenzialmente pericolose:

**Pericoli immediati:**

**Scontri e disordini pubblici** - Si vedono persone in quello che sembra un confronto con le forze dell'ordine (riconoscibile un agente con casco blu)

**Presenza di fumo/fumogeni** - C'è del fumo denso nell'area, che potrebbe indicare l'uso di fumogeni, lacrimogeni o altri dispositivi, riducendo la visibilità e potenzialmente causando problemi respiratori



# L10

## Punti principali visti

- Il sistema biometrico visto come classificatore che sbaglia con probabilità  $p$
- Distribuzione errori: Bernoulli, Binomiale
- FTA, FTE
- Dispensa Best Practices
- Stima con sistemi apprendenti
  - Overfitting
  - Partizione del dataset
    - K-FCV,
    - LOO,
    - LOPO (Leave One Person Out)
    - LNPO (Leave N Person Out)



# Appendici con il codice

Non richiesto all'esame

```

# Install required packages
!pip install deepface
!pip install opencv-python

# Import Libraries
import cv2
from google.colab.patches import cv2_imshow
from deepface import DeepFace

# Load Haar Cascade Classifier
face_cascade = cv2.CascadeClassifier(cv2.data.harcascades + 'haarcascade_frontalface_default.xml')

# Read Image
img = cv2.imread("face3.jpg")

# Check if image is loaded
if img is None:
    print("Could not open or find the image.")
else:
    # Perform Face Detection
    gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
    faces = face_cascade.detectMultiScale(gray, 1.1, 4)

    # Process Each Detected Face
    for i, (x, y, w, h) in enumerate(faces):
        cv2.rectangle(img, (x, y), (x+w, y+h), (255, 255, 0), 2)

        # Crop the face from the image
        face_crop = img[y:y+h, x:x+w]

        # Skip if face_crop is empty
        if face_crop.size == 0:
            continue

        try:
            # Use DeepFace to predict age and gender
            predictions = DeepFace.analyze(face_crop, actions = ['age', 'gender'])

            if isinstance(predictions, list) and i < len(predictions):
                age = predictions[i]["age"]
                gender = predictions[i]["dominant_gender"]

                # Draw age and gender on the image
                cv2.putText(img, f"Age: {age}", (x, y-10), cv2.FONT_HERSHEY_SIMPLEX, 0.8, (255, 255, 0), 2)
                cv2.putText(img, f"Gender: {gender}", (x, y+h+20), cv2.FONT_HERSHEY_SIMPLEX, 0.8, (255, 255, 0), 2)
            else:
                print(f"Skipping face at {(x, y, w, h)} due to mismatch between detected and analyzed faces.")
        except (ValueError, IndexError) as e:
            print(f"Skipping face at {(x, y, w, h)} due to: {e}")

# Display the Image
cv2_imshow(img)

```

Traccia di codice  
da ottimizzare e migliorare!  
(vedi compiti)