

Inverse Turing Test

Proof of
Personhood


Deep Fake
Detection


Fabio Scotti



OUTLINE

- Inverse Turing Test
- Proof of Personhood
- Deep fake
 - Cosa sono
 - A cosa servono (scopi leciti e illeciti)
 - Produzione dei deepfake come test dei sistemi biometrici
- Deep fake detection
 - Frame singolo
 - Video
 - Protezione con Challenge-Response
 - Test dei sistemi e Piattaforme
- Conseguenze penali in Italia






Inverse Turing Test

Inverse Turing Test (IIT)

(anche chiamato Reverse Turing test)



Partiamo dall'idea classica.

- Nel **Alan Turing Test** (1950)
→ *un umano* deve capire se sta parlando con **un altro umano o una macchina**.
- Nell'**Inverse Turing Test (ITT)**
→ *è la macchina* che deve capire se l'interlocutore è **umano o è una macchina**.
- Dal punto di vista biometrico e di sicurezza:
 - non vogliamo sapere *chi sei*
 - vogliamo sapere *cosa sei* → umano o non umano
- E' quindi **un problema di classificazione binaria**
 - risposta $\in \{umano, bot\}$



Inverse Turing Test (IIT)

E' quindi **un problema di classificazione binaria**

- risposta $\in \{umano, bot\}$

$$P(umano|X) > T$$

Dove:

- X = osservazioni comportamentali
- T = soglia di decisione

Nota: esistono versioni probabilistiche (e.g. reCAPTCHA v3) che ritornano invece direttamente la prob.
 $P(umano|X)$


Cosa si cerca di individuare

Definizione **operativa**

Un *Inverse Turing Test* è un test progettato per distinguere utenti umani da agenti automatici (bot), sfruttando capacità che:

- gli umani possiedono naturalmente
- le macchine (storicamente) faticano a replicare

Storicamente....



Ipotesi alla base

- Per un umano: facile
- Per una macchina: difficile (almeno storicamente)

Esempio classico **CAPTCHA**

- **C**ompletely **A**utomated **P**ublic **T**uring test to tell **C**omputers and **H**umans **A**part
- Viene richiesto di:
 - leggere testo distorto
 - riconoscere oggetti in immagini
 - ascoltare e trascrivere audio
 - Ecc.

Recentemente

Problema attuale

- Con CNN e Vision Transformer, molti CAPTCHA sono **aggirabili**
- → si è passati a test **comportamentali**






Qui il punto chiave è **non il puzzle**, ma **come ti comporti**.

- **Cosa misura (implicitamente)**
 - traiettoria del mouse
 - tempo di risposta
 - micro-esitazioni
 - coerenza temporale
- **Biometria comportamentale soft → Recaptcha**

ReCAPTCHA con mouse

L'uso del mouse rileva la dinamica umana



reCAPTCHA v3 (Google)



I'm not a robot



reCAPTCHA
Privacy - Terms

- Lavora **in background** analizzando il comportamento.
- Score di rischio (0.0 – 1.0)
 - Restituisce un **punteggio continuo** invece di un semplice *pass/fail*.
 - **1.0 = utente molto probabile umano**
 - **0.0 = altamente sospetto bot**
 - Permette logiche personalizzate: es. blocco < 0.3 , MFA tra $0.3-0.6$, ok > 0.6 .
- Valuta segnali come:
 - velocità e traiettoria del mouse
 - pattern di digitazione
 - tempo di permanenza
 - cronologia di navigazione sulla pagina
 - fingerprinting del browser (limitato)

$$P(\text{umano}|X) > T$$

reCAPTCHA v3 (Google)



I'm not a robot




reCAPTCHA
Privacy - Terms

Analisi comportamentale **continua**


- **All'apertura** della pagina
Stabilisce una "baseline". Un bot spesso carica solo le risorse necessarie; un umano carica la pagina e inizia a muovere il cursore.
- Durante lo **scroll**
Il modo in cui un umano scrolla (accelerazioni, pause per leggere) è profondamente diverso da uno script che "salta" direttamente a una coordinata (x,y).
- Al **focus** su un campo
Un bot incolla i dati istantaneamente; un umano clicca, il cursore lampeggia e inizia la digitazione.
- **Ripetuta** ogni X secondi
Serve a rilevare bot che rimangono "dormienti" in una scheda aperta per poi attivarsi in seguito.

BeCAPTCHA


- **BeCAPTCHA** è un sistema di CAPTCHA comportamentale progettato per distinguere un **utente umano** da un **bot** analizzando il modo in cui interagisce con uno smartphone, invece di basarsi su immagini da selezionare o testi da digitare.
- Il metodo impiega anche reti GAN per produrre traiettorie sempre piu' naturali, per poi addestrare le reti per la detezione dell'attacco



Fusioni di tecniche



Usando le conoscenze sviluppate nelle lezioni precedenti sulla **fusione a livello di score** e' possibile creare una fusione ottimale per la tua applicazione



Deepfake e Inverse Turing Test

- **Sembrano funzionalità simili ma in realtà rispondono a problemi diversi.**
- **Deepfake detection** chiede
 - *«questo contenuto è reale o sintetico»*
 - *«E' stato manipolato?»*
- **Inverse Turing Test** chiede
 - *«chi (o cosa) sta interagendo è umano o no?»*

Deepfake VS Inverse Turing Test

Dimensione	Deepfake Detection	Inverse Turing Test
Cosa analizza	Contenuto	Comportamento
Oggetto	Media (img/video/audio)	Agente  Cosa muove il mouse?
Domanda	"È falso?"	"È umano?"
Classe	Reale / Sintetico	Umano / Bot
Dominio	Computer vision / signal processing	Biometria comportamentale
Uso tipico	Media integrity	Access control / antifrode



Proof of Personhood

Identità digitale e Proof of Personhood

Proof of Personhood (PoP)

Insieme di **metodi, protocolli o sistemi** per verificare che un'entità online sia un essere umano unico e reale, non un bot o un account duplicato.

Metodi in fase di sviluppo:

- **Dati biometrici** come scansioni dell'iride o riconoscimento facciale.
- **Challenge comportamentali** come Pattern motori, digitazione
- **Verifica sociale**, dove persone già verificate garantiscono per i nuovi membri
- **Dispositivi personali** / Secure Enclave dove la prova è legata a **hardware personale sicuro**.

Alcuni progetti in atto

- **Worldcoin** (ora "World")
 - Lo analizziamo fra poco
- **Proof of Humanity**
 - Un progetto basato su Ethereum che combina video-verifica, depositi economici e dispute comunitarie (reverse Turing tests)



Alcuni progetti in atto

- **BrightID**

- Sistema di verifica basato su grafi sociali. Gli utenti partecipano a "connection parties" (virtuali o fisiche) dove si verificano reciprocamente. Non richiede dati biometrici ed è focalizzato sulla privacy.



- **Human Passport (ex Gitcoin Passport)**

- Usa un sistema di "stamps" (timbri) che verificano vari aspetti dell'identità digitale: account social verificati, possesso di NFT, partecipazione a **DAO** (Decentralized Autonomous Organization), transazioni on-chain. Più stamps accumuli, più alto è il tuo "punteggio di umanità".





World ID e World Coin

Un esempio di soluzione per la Proof of Personhood

WorldCoin → WorldID




Ideazione e Prototipazione (2019 - 2022)

- **Obiettivo:** Creare un sistema per distinguere umani e IA (Proof of Personhood) in vista di un futuro dominato dall'intelligenza artificiale.
- **Sviluppo:** Sam Altman e Alex Blania progettano l'**Orb**, il dispositivo biometrico per la scansione dell'iride, e creano il protocollo World ID.



Orb: the worldcoin scanner



Componenti

Ritroviamo i componenti della lezione sulle ottiche

Filtro NIR

(Passa NIR
e filtra VISIBLE)




LED Ring Near Infrared (NIR)
Range compatibile con iride
 $\approx 740\text{--}850\text{ nm}$



Specchio (per IR)
basculante
per cercare gli occhi
nella inquadratura

(solo i sistemi di fascia alta
hanno parti mobili)



Sensore CMOS senza filtro
visibile (per aumentare
sensibilità in nearIR),
grande risoluzione e rapporto
di forma per raccogliere
diverse posizioni della testa

Ottica passo
(prob.) C
e di tipo «tele»

Deepfake detection

1. Verifica della "Vivacità" (Liveness Detection)

- **Immagini Infrared.**


L'Orb è sensore **multispettrale**

- **Luce Infrarossa:** Analizza come la luce riflette sull'occhio umano; i materiali sintetici (come quelli usati per maschere o schermi) riflettono la luce in modo diverso dai tessuti biologici.

- **Sensori di profondità**


L'Orb verifica che l'occhio sia un oggetto tridimensionale reale e non una foto piatta o uno schermo ad alta risoluzione.

Deepfake detection



2. Risoluzione e Micro-Dettagli

- Mentre i deepfake possono sembrare perfetti su uno schermo, l'Orb **cattura dettagli dell'iride microscopici** che l'intelligenza artificiale attuale non è ancora in grado di riprodurre con precisione fisica assoluta.
 - Vedremo queste tecniche nelle prossime lezioni sull'antispoofing dell'iride.



Passi della creazione del worldCoin


FASE 1: Scansione (L'Orb)

- L'occhio viene inquadrato dall'Orb (telecamera biometrica).
- Viene scattata una foto ad alta risoluzione dell'iride (luce infrarossa).
- Sensori 3D verificano che tu sia un umano vivo (non una foto o un robot).



FASE 2: Conversione (IrisCode)

- Un algoritmo trasforma i dettagli dell'iride in un codice numerico unico (iriscode).
- Privacy: La foto originale dell'occhio viene cancellata dall'Orb.
- Resta solo il numero (impossibile tornare indietro alla foto dell'occhio).



Passi della creazione del worldCoin

FASE 3: Verifica (Unicità)

- Il codice viene inviato nel database globale (blockchain).
 - Perché la blockchain?
 - Perché è un **registro pubblico e immutabile**. Una volta scritto lì che "questo codice umano esiste", nessuno può cancellarlo o modificarlo.
 - **Anonimato**: Importante ricordare che sulla blockchain non finisce il tuo nome, ma solo una prova crittografica della tua esistenza umana.
- Il sistema controlla che quel codice non esista già (evita registrazioni doppie).
- Se è nuovo, viene creato il tuo World ID (Orb's unique private key).

Passi della creazione del worldCoin

FASE 4: Attivazione (App & Token)


- Il World ID viene salvato sul tuo smartphone.
- Ricevi i token WLD come incentivo per aver partecipato.

NOTA:


Worldcoin usa tecnologia Zero-Knowledge Proof

- Quando con WordID ti autentichi su un sito, tu non invii il tuo IrisCode. (Semplificando... Il tuo telefono invia solo una prova matematica che dice: "Esiste un IrisCode nel database mondiale che mi appartiene, ma non ti dico qual è").

Riassumendo



Enrollment e claim del



In generale \$TOKEN indica che è un asset con valore di mercato che è scambiabile

Esempio di DBC: Worldcoin (esordi)

<https://worldcoin.org/>

Prova di unicità iniziale

Claims

- “Worldcoin is building the world’s largest identity and financial network as a public utility, giving ownership to everyone.”
- “We aim to create universal access to the global economy regardless of country or background, accelerating the transition to an economic future that welcomes and benefits every person on the planet.”

Creazione del World ID

- Iris scanning → irisCode → Orb’s unique private key → blockchain
- **Dopo** la prova di essere umani e la creazione della chiave, **Non serve più l’Orb per usare i Worldcoin**

Claim....

Problema del Deepfake risolto

DeepFace ti protegge dai
deepfake dannosi online

Progettato per la comunicazione in tempo reale, DeepFace usa l'autenticazione tramite World ID per confermare che la persona con cui stai parlando è una persona reale e non un deepfake. L'altra persona può facilmente dimostrare di non essere un deepfake e aiutare a costruire fiducia online.

Il Progetto WORLD in sintesi


Il progetto è passato dall'essere una "criptovaluta per tutti" a diventare un'infrastruttura di **identità digitale globale** per proteggere gli umani dalle imitazioni dell'IA.

Fasi attuali del progetto

- **Evoluzione in "World Network" (Ottobre 2024 - Oggi)**
- **Rebranding:** Il progetto cambia nome da Worldcoin a **World**.
- **Nuova Tecnologia**
Lancio dell'**Orb 2.0** (più veloce e «sicuro») e di **World Chain**, una rete blockchain dedicata esclusivamente agli esseri umani verificati per ridurre lo spam dei bot.
- **Deepfake**
Focus totale sulla lotta ai deepfake online tramite l'integrazione del World ID in app come FaceTime, WhatsApp e Zoom.

Face Auth per World ID

- Confronto locale per accedere all'app
- Serve a sbloccare l'app e a confermare che chi ha in mano il telefono è la stessa persona che ha fatto la scansione originale. (non puoi vendere il tuo ID)



World Network makes its Italian debut (Rome)

- Nel gennaio 2026 inizia la campagna di acquisizione anche in Italia
- Integrato nelle banche
- **NON E' UN CONSIGLIO FINANZIARIO!!**



Revolut Personale Business Giovani Società Accedi Registrati

Scopri l'economia delle criptovalute

Come acquistare Worldcoin in Italia

Tutto quello di cui hai bisogno per muovere i primi passi nel mondo delle criptovalute è a portata di mano: trovi lezioni, dati aggiornati sui prezzi e molto altro. Scopri come acquistare Worldcoin nella stessa app che usi per gestire il tuo denaro e inizia a investire a partire da solo 1 £ (o l'importo equivalente in EUR).

EUR ▼ 0,32€
↕
WLD ▼ 1
Il nostro tasso corrente 1 WLD = 0,323 €

Le commissioni non sono incluse nel tasso indicato. Consulta l'app Revolut per i dettagli dei prezzi in tempo reale. Crypto non è un prodotto regolamentato né protetto. I prezzi sono volatili e il valore dei tuoi asset può diminuire.

Inizia subito



Viene mostrato in aula un filmato



Commento sui video mostrati in aula
Non ho **mai** pronunciato nessuna di queste frasi....
Le ho scritte in uno script in un piattaforma online
chiamata HeyGen per la generazione di contenuti
automatici.

Deepfake


Il termine "deepfake" si riferisce a un contenuto creato utilizzando l'intelligenza artificiale, in particolare algoritmi di apprendimento profondo (deep learning).

I deepfake sono noti per la loro capacità di generare video, immagini o audio che appaiono sorprendentemente realistici, ma che sono in realtà falsificati o manipolati.



Frodi e Deepfake

Esaminando il report 2025 sulle frodi una delle maggiori firm del settore (Onfido) risulta che i deepfake stanno diventando uno dei metodi più frequenti e pericolosi



Fraud-as-a-service...

What's particularly concerning is that more and more fraudsters are using a combination of attack vectors, such as:

- ✓ Leveraging personally identifiable information (PII) obtained through data breaches and phishing to create synthetic identities
- ✓ Fraud rings sharing methodologies and offering fraud-as-a-service to arm more amateur fraudsters
- ✓ Fraudsters submitting deepfakes via injection attacks

Potentially, all of the attack vectors in the chart could be combined.

Fraud is becoming more complex and multi-layered, and therefore requires a multi-pronged approach to prevent it.

Spoofing e Deepfake

Sono due cose leggermente diverse...


- **Deepfake**

- Qui andremo a cercare di capire se il sample è stato creato in modo artificiale. Esempi:
 - un volto è sintetico?
 - Il «padrone» della voce ha detto veramente questa affermazione?



- **Spoofing** e attacco al sensore

- Nelle prossime lezioni ci occuperemo anche dello spoofing eseguito al sensore. Esempi:
 - ho davanti uno schermo o una maschera?
 - la voce esce da un registratore?



E' possibile **che si combinino i due approcci** usando un attacco al sensore per introdurre un deepfake

- Per esempio con uno schermo si proietta un video davanti alla telecamera del sistema biometrico o di videosorveglianza
- Fare enroll **remoto** di una persona che non esiste!

Tipi di deepfake per tipo di output

Video

Questi sono video in cui il viso di una persona è sostituito con quello di un'altra, mantenendo le espressioni facciali e i movimenti originali. Sono spesso utilizzati per creare contenuti satirici o per scopi di intrattenimento, ma possono anche essere usati per scopi illegali, come la diffamazione

Audio

In questi deepfake, la voce di una persona viene clonata o modificata per dire cose che non ha mai detto. Questa tecnologia viene utilizzata in vari campi, inclusa la sintesi vocale per l'assistenza ai disabili, ma presenta anche rischi in termini di frodi e disinformazione

Immagini

Sono immagini statiche modificate o generate per apparire reali. Questo include non solo la manipolazione dei volti, ma anche la creazione di persone completamente inesistenti (esempio riportato di fianco)

Testo

Esistono esempi di IA che generano testi che sembrano essere stati scritti da persone reali. Questo può includere articoli di notizie falsi, post sui social media, o libri

Emotivi

I deepfake possono essere progettati per cambiare lo stile o l'emotività di un messaggio, rendendo la comunicazione ancora più persuasiva o ingannevole. Questa capacità di alterare non solo l'aspetto fisico ma anche le sottigliezze emotive e stilistiche rende i deepfake particolarmente potenti e potenzialmente pericolosi.



Esempi di impiego

Deepfake di Personaggi Pubblici

Questi sono spesso i più noti, dove i volti di celebrità o politici vengono inseriti in video in cui non sono mai apparsi.

Divertimento/Intrattenimento

Alcune applicazioni consentono agli utenti di creare deepfake per scopi di intrattenimento, come cambiare il proprio aspetto in un video o inserire il proprio viso in scene di film famosi.

Sintesi di Espressioni

Questi deepfake modificano le espressioni facciali in un video per riflettere diverse emozioni o per sincronizzare il movimento delle labbra con un nuovo tracciato audio.

Ricerca e l'Educazione

In alcuni contesti, i deepfake possono essere utilizzati per scopi educativi, come la simulazione di eventi storici o la creazione di scenari di apprendimento interattivi.

Deepfake per i sistemi biometrici

Impieghi **leciti**

- **Creazione di nuovi individui**

Questi sono spesso i più noti, dove i volti di celebrità o politici vengono inseriti in video in cui non sono mai apparsi.

- **Test delle metodologie di antispoofing**

Alcune applicazioni consentono agli utenti di creare deepfake per scopi di intrattenimento, come cambiare il proprio aspetto in un video o inserire il proprio viso in scene di film famosi.

Nvidia

Eye Contact Feature


- L'effetto "Eye Contact" sposta gli occhi del parlante per simulare il contatto visivo con la telecamera, ottenuto stimando e allineando lo sguardo.
- Di fatto è un deepfake: simula attenzione!
- Gli occhi mantengono
 - il loro colore naturale
 - i battiti delle palpebre,
- Funzione di disconnessione nel caso in cui si guardi troppo lontano, per effettuare una transizione fluida tra occhi simulati e reali.




Manipolazione/ Data augmentation

- SW come Face Poke o Expression editor permettono di modificare e alterare fotografie con un realismo sempre maggiore
- Quando vi saranno tool funzionanti in tempo reale, si potranno utilizzare per rispondere ad una challenge (vedi lucidi successivi)

<https://facepoke.net/>



<https://huggingface.co/spaces/fffiloni/expression-editor>






Avatar e individui sintetici

- Rimanere giovani e dinamici in rappresentazioni, per esempio permettere a Tom cruise di saltare dai tetti come quando aveva 20 anni...
- <https://www.bbc.com/news/entertainment-arts-67611691>
When rock band Kiss played their final farewell concert in New York this weekend, they ended with a gesture that will ensure their digital immortality.
 - As they left the stage at Madison Square Garden, the band were replaced by flying avatars who launched into the hit song God Gave Rock 'n' Roll to You.
 - Gene Simmons said the band could now be "forever young and forever iconic".
<https://www.youtube.com/watch?v=sLQjnVNVe3w>


Problematiche associate ai deepfake (impieghi **illeciti**)

- Non vedere i Kiss live, ma piuttosto solo come avatar non è il vero problema..
- Il grado di realismo della tecnologia sul mercato pone rischi molto più seri e conseguenze legali e commerciali decisamente importanti
- In questa demo si può vedere un esempio in video



Impieghi **illeciti** (cont.)

Fake news/contents, accounts



- Siamo di fronte ad un nuovo livello: generazione di contenuti provocatori e indirizzati sempre più realistici per fini
 - Commerciali (click bait)
 - Politici
 - Delinquenziali (truffe, estorsioni, lavaggio del denaro sporco, ...)
- Conseguenze di diritto civile e penale
- Esempi: generazione di
 - volti noti (in filmati, con audio) in contesti fake
 - account completamente fake con dati verosimili

Questo argomento ci fa rivedere in modo completamente diverso le tecnologie di generazione sintetica dei tratti biometrici attuali quando usate per fini illeciti

Vietato per legge: il corpo e' sotto "copyright"

Prime promulgazioni

- Giugno 2025, Danimarca
Il disegno di legge danese rappresenta un'iniziativa pionieristica in Europa per contrastare i deepfake, estendendo i diritti d'autore alle fattezze fisiche e alla voce delle persone
- mira a modificare la legge sul copyright per includere il corpo, i tratti somatici e la voce come elementi protetti, simili alle opere d'arte, che non possono essere riprodotti senza autorizzazione
- Saranno previste sanzioni per le piattaforme che diffondono contenuti manipolati senza consenso, con "multe severe" per chi non si adegua

3 tipi principali

Face swaps



AI Prompt: Man covering face with a paper print mask of a human face

In face-swapped images or videos a source face is superimposed onto a target head. The most basic way of doing this results in a 'cheapfake', where the source face is crudely pasted over the top of the target face. True deepfake face-swaps are much more sophisticated — they use AI to morph and blend the source face onto the target.

Fully-generated images




AI Prompt: Woman selfie portrait living room looking at camera blue hair tattoo

These are created by generative models that have been trained to produce extremely realistic images of faces.

In this scenario, a new face is produced entirely from scratch, rather than superimposing one face onto another.


Lip-sync videos



AI Prompt: older man talking looking at camera mouth half open

In these videos, the original person stays the same, but their lips are manipulated (and sometimes combined with deepfaked voices) to make it appear as though they are saying something they never said in the original video.


I face swap stanno diventando molto sofisticati interpretando il 3D del volto



I face swap sono una forma di immagini sintetiche create utilizzando due input, in cui un criminale combina caratteristiche da un volto, come il **movimento**, con l'aspetto di un altro volto per creare un nuovo output video sintetico usando modelli anche tridimensionali. L'output presenta le caratteristiche dei tratti facciali dell'individuo genuino. L'immagine può corrispondere alla fotografia del documento d'identità governativo durante un tentativo di verifica della vitalità se la tecnologia utilizzata non è dotata delle ultime difese di antispoofing


Tecniche «classiche» morphing and image manipulation sui documenti di identificazione

The full chain of morphed passports



Uso delle AI generative

Diventa assolutamente facile creare immagini realistiche con le caratteristiche di un utente da impersonificare o che si adatta meglio alla frode in corso




AI PROMPT

Portrait of middle aged man
serious blue lighting

Generazioni di immagini e video sintetici con le GANs

Applicazioni delle GANs
in biometria

- Data augmentation (lecito)
- Attacchi (illecito o lecito se per scopi di test)



Esempi di fake faces




Attuali trend nel deepfake

- Una recente analisi di OnFido mostra un aumento di 31 volte della frode deepfake dal 2022 al 2023.
- Tendenza chiave: Biometria, la frontiera della frode

I truffatori stanno diventando creativi nel modo in cui mirano alla biometria.

Ma la biometria rimane una delle strategie di difesa più robuste.

La verifica biometrica registra un numero di tentativi fraudolenti tre volte inferiore rispetto ai documenti.



AI PROMPT


SETTINGS: USE IMAGE REFERENCE AT 80% SIMILARITY >

'Ethnic origin [variable]'

Frodi documentali con e senza biometria

Report OnFido 2025

Average fraud rates



Frodi documentali con e senza biometria

Report OnFido 2023

Nel 2023 i truffatori si sono concentrati sempre di più sulla frode biometrica, con un lieve aumento dei tassi di frode biometrica al 1,31%, il doppio rispetto al 0,68% del 2022.

Comunemente utilizzano documenti legittimi per i controlli di verifica, seguiti dalla modifica del loro aspetto per i controlli biometrici, ricorrendo spesso a cheapfakes e deepfakes.

Nonostante ciò, la frode biometrica è ancora significativamente inferiore alla frode documentale, tre volte meno, evidenziando l'efficacia dei sistemi biometrici, specialmente quelli con il rilevamento della vitalità, nel deterrenza la frode.



Per esempio la tecnologia biometrica proposta da Onfido riduce il tasso di successo degli attacchi di 10x

Aggiornamento attacchi biometrici fine 2024: video

Gli attacchi ai sistemi biometrici nel 2024 sono stati portati sui video, selfie, o «motion» (movimenti richiesti)

Gli attacchi con deepfake stanno aumentando molto velocemente!




Photo on screen (selfie only):

A photo of an image on screen (such as a profile picture from a social media account)

Photo of printout (selfie only):

A photo of an image printed on paper

Photo/Video of ID: A photo or video of the face on the identity document

2D mask: A photo or video of a 2D-printed mask

3D mask: A photo or video of a 3D mask or other 3D object



Deepfake: Digitally manipulated photo or video where a person's face is altered to appear as someone else

Video on screen (video/motion only): A video of a video on a screen

Video of printout (video/motion only): A video of an image printed on paper

Aggiornamento attacchi biometrici fine 2024: selfie e motion

Nelle altre categorie di ingresso biometrico, i deepfake intervengono maggiormente quanto l'ente certificatore richiede dei movimenti del volto («motion»)



Alcuni tool recenti pubblici per la creazione di deepfake (Swap Face)

- **Swap Face**

- Uno strumento facile da usare per lo scambio di volti in video, immagini e streaming.
- Richiede una buona scheda grafica per modalità di qualità superiore come Pro ed Expert, e i risultati possono variare in base all'hardware del computer.

- **Roop**

- Uno strumento deepfake open-source accessibile tramite GitHub e utilizzabile nel cloud tramite Google Colab, senza necessità di una scheda grafica di fascia alta.
- Coinvolge un processo semplice di quattro passaggi in Colab, consentendo agli utenti di creare facilmente video deepfake.

- **Facilità d'Uso**

- Sia Swap Face sia Roop sono progettati per una facile installazione e utilizzo. Non sono al livello degli attacchi reali, ma possono aiutare le reti per essere allenate

Voice cloning




- La clonazione della voce, è una tecnologia che utilizza l'intelligenza artificiale per analizzare le caratteristiche uniche della voce di una persona e poi replicarla.
 - In altre parole, è come creare una copia digitale della voce di qualcuno che può essere usata per generare parole e frasi che quella persona non ha mai detto realmente.
- Tracce audio praticamente indistinguibili dalla sorgente. Perfetti per video, audiolibri, podcast, videogiochi, ecc.
- Esempio di provider <https://elevenlabs.io/voice-cloning>
 - Create your AI voice clone from just a few minutes of audio. Reach unparalleled accuracy across 29 languages and 50+ accents. ElevenLabs Voice Cloning is the most advanced voice cloning AI available.

Utilizzi positivo del voicecloning


- **In caso di perdita della voce**
clonare la voce utilizzando l'intelligenza artificiale per motivi di sicurezza e ricordo personale.
- **Nuove applicazioni**
dalla creazione di audiolibri con la propria voce, la risposta automatizzata a domande dei clienti, intrattenimento, nel servizio clienti, campo medico per raccomandazioni.
- **Capacità multilingue della voce clonata**
la voce clonata possa parlare in diverse lingue, tra cui inglese e coreano
- **Considerazioni etiche e impatto futuro**
rischi di furto d'identità e uso improprio per frodi. La legislazione non è ancora pronta e probabilmente sarà sempre in ritardo. La protezione e dissuasione quindi non sarà legislativa, ma principalmente «tecnica»

Attacchi in real time




- Free Real Time Voice Changer <https://voice.ai/>
- Società come Nuance (oltre ad occuparsi di riconoscimento biometrico della voce) stanno sviluppando tecnologie contro gli usi impropri del voice cloning.
 - Tratteremo meglio questi argomenti nella lezione dedicata all'antispoofing.

MS Azure AI Speech text to speech avatar



Azure AI Speech text to speech avatar, una nuova funzionalità che consente agli utenti di creare video con avatar parlanti utilizzando l'input di testo e di sviluppare **bot interattivi in tempo reale** addestrati utilizzando immagini di esseri umani.




DeepMasterPrints

esempio di attacco tramite AI generativa

Verifica

Enrollment



Sora generazione di cameo

Contesto

- Sora 2 (OpenAI, Ottobre 2025): modello avanzato di generazione video+audio realistici.
- Funzione *cameo*: inserimento di un volto/voce reale in video sintetici ad alta fedeltà.
- Opportunità creative → ma anche **nuovi rischi di abuso** (deepfake convincenti).

Minacce principali

- **Furto d'identità biometrica**: il volto dell'utente usato senza consenso.
- **Disinformazione**: diffusione di video falsi ma realistici.
- **Frode e impersonificazione**: accesso a sistemi basati su riconoscimento facciale/voce.
- **Cyberbullismo e danni reputazionali**.

Sam Altman che ruba una GPU?



Sora generazione di cameo (esempio di policy nativa)


Vediamo come OpenAI come ha deciso di cercare di proggere da abusi gli utenti

Policy di protezione dell'utente

- **Consenso e controllo:** solo l'utente decide dove e come usare il proprio *cameo* (revocabile in ogni momento).
- **Provenance e watermarking:** sistemi di tracciabilità e marcatori digitali nei contenuti generati.
- **Moderazione attiva:** filtri automatici + revisione umana di abusi.
- **Parental controls** per utenti minorenni.
- **Limitazioni di default:** numero di generazioni/giorno, restrizioni più forti per i teen.

Come difendersi come utenti

- **Evitare di condividere video/registrazioni inutili** che possano essere catturate per training.
- **Usare sistemi con autenticazione multifattore:** non basarsi solo su riconoscimento facciale/voce.
- **Verificare la provenienza dei contenuti** (controllo fonti, watermark ufficiali).
- **Attivare notifiche di cameo** (visibilità dei contenuti in cui si compare).
- **Educazione digitale:** riconoscere i deepfake, adottare un atteggiamento critico verso i contenuti online.



Approcci generali per la deepfake detection



Approcci generali

Analisi Forense

Analisi dettagliata dei media per identificare segni di manipolazione. Include l'esame di

- inconsistenze nei pixel,
- artefatti introdotti dai processi di generazione dei deepfakes,
- discrepanze nella resa di elementi come l'illuminazione o le ombre.

ATTENZINE: USA, nello stato di Washington, c'è stato il primo caso di [divieto dell'utilizzo dell'AI](https://www.nbcnews.com/news/us-news/washington-state-judge-blocks-use-ai-enhanced-video-evidence-rcna141932?) per migliorare delle immagini di un triplice omicidio. I filmati che erano stati migliorati con un software che utilizza l'AI sono infatti stati rigettati dal giudice. Per come funziona la giustizia americana, questo costituisce un precedente importante.

<https://www.nbcnews.com/news/us-news/washington-state-judge-blocks-use-ai-enhanced-video-evidence-rcna141932?>

Approcci generali

Verifica dell'Autenticità del Contenuto

Si possono utilizzare metodi come il tracciamento della provenienza dei file o **l'analisi dei metadati** per determinare se il contenuto è stato modificato come per esempio metodi basati su **blockchain**

- **Nuovi standard tecnici come la C2PA**
Coalition for Content Provenance and Authenticity (C2PA) stanno creando standard tecnici come i **metadati crittograficamente firmati, noti come C2PA manifests** per verificare la
 - fonte,
 - la cronologia
 - l'origine dei contenuti.

Soluzioni basate su Blockchain


- Come si sta iniziando a fare per la notizie fake, si sta pensando a meccanismi di autenticazione basati su blockchain. Non esistono ancora soluzioni commerciali.
- Es. La KBC Bank, la terza più grande banca belga, ha creato un metodo basato sui concetti di **proof of authenticity, proof of consistency a proof of existence**, con l'obiettivo di certificare le proprie rassegne stampa, in particolare quelle relative a dati finanziari
 - L'utente (giornalista, agenzia di stampa, editore) può verificare se il pdf della rassegna stampa in suo possesso corrisponde effettivamente a quello ufficiale rilasciato dalla Banca, per contenuti e data.

Approcci generali

Rilevamento Basato su Intelligenza Artificiale

Algoritmi di apprendimento automatico possono essere addestrati a distinguere tra contenuti reali e deepfakes attraverso esempi.

- Si analizzano caratteristiche sottili e complesse, anche non visibili ad occhio nudo che sono difficili da replicare o nascondere nei deepfakes.
- La qualità del riconoscimento dipende dal
 - Modello
 - Metodo di apprendimento
 - Qualità e completezza dei dati di addestramento



Approcci generali

Challenge-Response Authentication

- In questo metodo, si chiede all'entità (persona o sistema) di rispondere a una sfida imprevista.
 - Per esempio, in un contesto di video, si potrebbe chiedere all'individuo nel video di compiere un'azione specifica o di rispondere a una domanda inaspettata. Se il video è un deepfake, non sarà in grado di rispondere in modo adeguato.
- **Analisi del Comportamento e della Consistenza**
Questo approccio analizza le inconsistenze nel comportamento o nella biometria. Esempi di analisi di tratti che potrebbero essere difficili da replicare accuratamente nei deepfakes
 - movimento degli occhi
 - le espressioni facciali
 - modo di parlare o accenti

Challenge-response authentication

Nasce nel contesto della cybersecurity.

- Questo metodo di autenticazione implica un processo in cui una parte (il verificatore) presenta una sfida (come una serie di numeri o una stringa di testo) e l'altra parte (l'utente o il dispositivo che cerca l'accesso) deve fornire una risposta corretta per essere autenticata

Nel nostro biometrico e della detezione dei deepfake

1. Challenge (Sfida)


In questo passaggio, il sistema pone una "sfida" al soggetto in esame. Ad esempio, potrebbe chiedere di modificare l'espressione facciale in un certo modo, muovere la testa in una direzione specifica, o pronunciare una frase particolare. Queste richieste sono create per essere semplici per un essere umano reale da eseguire, ma difficili per un deep fake da replicare accuratamente.

2. Response (Risposta)

Il soggetto deve poi rispondere a questa sfida. In un contesto ideale, una persona reale sarebbe in grado di rispondere in modo naturale e coerente con la richiesta, mentre un deep fake potrebbe non riuscire a replicare la risposta richiesta in modo convincente o in tempo reale.

3. Analisi e Verifica

Il sistema poi analizza la risposta per determinare se è autentica o meno. Questo può includere l'analisi dei movimenti, la sincronizzazione labiale, la coerenza delle espressioni facciali, e altri dettagli che possono essere difficili da replicare per i deep fakes.



La difesa dipende dall'input!

- Singolo frame
 - Caratteristiche e alterazioni
 - Mancanza di gestalt
 - Decolorazioni
- Video senza audio
 - Pletismografia remota
 - Flusso ottico e variazioni non conformi ad un volto
- Video con audio
 - Sincronia parlato-voce
 - Antispoofing multimodale
 - canali separati (audio + video)
 - fusione delle probabilità di spoofing con i due canali
 - Uso di challenge linguistiche come dire una specifica parola e controllare parlato e sincronia parlato-video


Singolo frame

- **Transizione di colore**

- Nelle deepfake di neural puppetry e faceswap, il volto viene manipolato.
- A volte, si può notare una transizione di colore netta ai bordi dell'area manipolata dal software deepfake.

- **Accessori**


- Elementi come gli occhiali potrebbero sembrare convincenti in un primo momento, ma se osservati da vicino, potrebbero contenere artefatti.



Singolo frame


- **Sfondo o contesto sfocato**

- Le deepfake di StyleGAN sono buone nel creare volti, ma poco abili nel creare contesti coerenti. Controlla lo sfondo e l'abbigliamento, ad esempio, per vedere se hanno senso.



- **Aspetto degli occhi innaturale**



- Gli occhi sono piuttosto difficili da deepfake a causa della loro complessità. Verifica se i riflessi negli occhi hanno lo stesso angolo. La persona nel video batte ciglio? Le iridi di entrambi gli occhi sono ugualmente grandi?



Source: GAO; conceived from DARPA image at <https://www.darpa.mil/news-events/2019-09-03a>. | GAO-20-379SP

La «Gestalt» manca ancora, ma per poco...


La teoria della Gestalt, originaria della psicologia, si concentra sul modo in cui percepiamo gli elementi come parti di un tutto più grande anziché in isolamento. Questa teoria è particolarmente rilevante nell'ambito dell'intelligenza artificiale (AI) e del riconoscimento delle immagini.



Esempio di challenge Motion biometric verification (video)

- Inserire dei movimenti specifici e diversi per ogni individuo per controllare la liveness, il 3D e la risposta
- Esempio ONFIDO
Onfido Motion è la nostra soluzione di verifica biometrica di prossima generazione che ferma frodi sofisticate con un semplice movimento della testa. È conforme al livello 2 del PAD di iBeta, e il 95% dei risultati viene restituito in pochi secondi

<https://youtu.be/n4WeopCeqLs>



Esempio di Challenge-Response:

Sincronia parlato-video

(video con audio)


- Un sistema commerciale (BioID) ha aumentato la sicurezza del riconoscimento facciale valutando il flusso ottico del movimento delle labbra tra due fotogrammi.
- Recentemente anche ONFIDO richiede di pronunciare una sequenza di numeri dati e casuali durante il video di riconoscimento
- Esistono brevetti per la detezione degli echi dal cellulare che dimostrano la presenza fisica di una persona vicino
- Approfondiremo questi temi nelle prossime lezioni

Liveness anti-spoofing by rPPG in realtime: Server Intel (x video)


- Intel ha realizzato nel 2022 la prima piattaforma online per la detezione dei deepfake
- Il cuore del sistema è FakeCatcher (rPPG) + eye gaze detection (Intel Xeon Scalable Processor, OpenVINO™ toolkit)

<https://www.intel.com/content/www/us/en/research/blogs/trusted-media.html>

Intel Optimized Stack for Media Analytics



Create flexible solution ranging throughput, latency and dense solutions through intel® architecture portfolio




Ulteriori informazioni sfruttabili



Segnali di rilevamento delle frodi che possono mitigare le frodi documentali e biometriche non visive

- integrità del dispositivo
- intelligenza di rete
- segnali di geolocalizzazione
- scansione NFC
 - fornisce un ulteriore livello di protezione durante l'analisi dei documenti di identità supportati

Deepfake detection: performance degli umani




L'uomo è accurato a trovarli?

Affrontiamo un modello generativo recente


- <https://www.iproov.com/spot-deepfake-quiz>

Which of these is a deepfake?



- Solo il 24% dei consumatori sembra essere in grado di trovarli...

Studio recente



- Dr. Klaire Somoray and Dr. Dan J Miller from James Cook University have published a study in *Computers in Human Behavior*
- 450 people and showed them 20 videos, 10 of which were real and 10 of which were deepfakes.
- On average, participants correctly identified approximately **12 out of 20 videos**
- Teaching people detection strategies did not impact detection accuracy or detection confidence, nor did time spent per video,

Altri risultati

Gli studi più citati (MIT, UCL, UC Berkeley, Microsoft, Synthesia benchmark, ecc.) mostrano che:

- *Accuracy umana media* $\approx 50\% - 65\%$

In molti casi risulta vicina a $\approx$ *livello random (coin flip)*

In particolare:


- Deepfake facciali statici: 55–60%
- Video deepfake moderni (GAN 2023–2025): 50–55%
- Audio deepfake: spesso $< 50\%$

Fattori che influenzano la performance umana

Realismo percettivo

- Le GAN moderne hanno:
- coerenza temporale
- riflessi oculari realistici
- micro-espressioni coerenti
- sincronizzazione labiale accurata

Gli artefatti “classici” (blurring, blinking anomalo) non sono più affidabili.



Classificazione con AI
Catena di passi

Esistono servizi online per la detezione

Servizi basilari

- <https://weverify.eu/tools/deepfake-detector/>
- <https://deepfakedetector.ai/>
- <https://www.duckduckgoose.ai/deepfakeproof>
(estensione del browser)

Diversamente seguendo la politica “make or buy” con esito “make” serve realizzare un modello per la propria applicazione. Vediamo come!

DeepFake-o-Meter

- risposta a queste minacce, un team di ricercatori dell'Università di Buffalo, guidato dall'esperto Siwei Lyu, ha sviluppato un **programma per smascherare i filmati fasulli**: il *DeepFake-o-Meter*, una piattaforma open-source e [accessibile a chiunque](#) con una semplice registrazione gratuita, che permette di analizzare contenuti sospetti in modo rapido ed efficace.
- https://zinc.cse.buffalo.edu/ubmdfl/deep-o-meter/home_login

Analisi dei risultati del video fake di richiesta a Gianni

The likelihood score derived from the method indicates the probability of the input being fake. This score reflects the extent to which the input shares characteristics with the real or fake data labeled in the training set of the method, as reported in the original study, supported by correlation statistics. However, it is important to note that this score should not be considered as providing deterministic result.

Detector	Result	Details
AltFreezing (2023)	61.9% AI-Generated Likelihood	View detail
LIPINC (2024)	100.0% AI-Generated Likelihood	View detail
LSDA (2024)	80.0% AI-Generated Likelihood	View detail

Upload Another File

Check Submission History



Task: Synthesized Video/Image Detection

Sample Detail:

- Resolution: 720 x 1280
- Codec: h264
- Bitrate: 1920 kbps
- Duration: 17.64 seconds
- FPS: 25.0
- File Size: 4370.17KB

Analytic Name: Isda

Analysis Date: 2024-11-26 23:06:13.477287

Result: {'Real Probability': '0.20011546942922803', 'Fake Probability': '0.799884530570772'}

Analytic Description: Saved in output path, output Video/Image with bonding box and label

Analysis Scope: Testing if a video/image is fully synthesized or not.


Reference:

Code Link:

Servizi professionali


- **Incode Deepsight** – Enterprise-grade deepfake detection
 - ideale per: banche, fintech, piattaforme con alta sicurezza.
- **Sensity AI** – Multimodal deepfake detection + reporting forense
 - **Ideale per:** aziende con necessità di accurata verifica multimediale e compliance
- **Reality Defender** – Deepfake detection per API aziendali
 - **Ideale per:** team di sicurezza, KYC automation, piattaforme di social media.
- Altri: Mitek System, AuthenticID, DuckDuckGoose AI, Veridas

Catena di inferenza classica



Attenzione al downsampling che farà la rete deep nel suo primo strato (per esempio andando a 256x256 pixel). Per questo è molto importante trovare il volto e tagliare (crop) l'immagine attorno al volto, questo è fondamentale per avere i dettagli necessari per la detezione del deepfake


6 passi per l'allenamento di modelli AI per la deteazione



Trova un modello adatto da un insieme di modelli disponibili per la classificazione. Questi modelli includono modelli basati sull'apprendimento profondo, modelli basati sull'apprendimento automatico e modelli statistici

Per immagini e video

Approcci basati su Deep learning




Uso di reti ricorrenti (RNN) per sequenze di frame

Illustrazione della strategia generale per l'apprendimento di sequenze temporali di t fotogrammi nei video

Strutture più diffuse per l'apprendimento temporale nelle sequenze di dati

- Le Long-Short Term Memory (LSTM)
- Gated Recurrent Unit (GRU)



Database di fake per training di modelli



- **Deepfake Detection Challenge (meta)**
Dataset creato per una sfida di rilevazione deepfake, contenente una varietà di video manipolati e autentici.
- **Celeb-DF**
Un set di dati che si concentra su video deepfake di celebrità, offrendo esempi realistici di manipolazioni.
- **DeeperForensics-1.0**
Comprende un elevato numero di video deepfake, con enfasi sulla diversità delle condizioni di illuminazione e qualità video.
- **Real and Fake Face Detection**
Include immagini di volti reali e falsi, utilizzato principalmente per testare algoritmi di classificazione.
- **WildDeepfake**
Dataset che raccoglie video deepfake trovati in ambienti online reali, utile per testare la rilevazione in condizioni non controllate.
- **Fake Face in the Wild**
Simile a WildDeepfake, concentrandosi su immagini e video di volti falsi rilevati in ambienti online naturali.
- **FaceForensics++**
ampio dataset di video manipolati, che include vari tipi di deepfake

Ci stiamo avvicinando a questa scena?

- Do Androids Dream of Electric Sheep? (retrospectively titled Blade Runner: Do Androids Dream of Electric Sheep? in some later printings) 1968, romanzo di Philip K. Dick.
- In una stanza scarsamente illuminata e dall'atmosfera cupa, Rick Deckard, un burbero e riflessivo cacciatore di replicanti, si siede di fronte a un Nexus, un essere quasi indistinguibile da un umano. Deckard utilizza un dispositivo chiamato Voight-Kampff, una macchina sofisticata progettata per misurare le reazioni emotive, che aiuta a distinguere i replicanti dagli umani.
- Durante l'interrogatorio, Deckard pone una serie di domande progettate per provocare risposte emotive, osservando attentamente i cambiamenti nelle espressioni del Nexus e i piccoli segni di turbamento. La macchina analizza le reazioni pupillari e le espressioni facciali del Nexus, cercando le sottili incongruenze che potrebbero rivelare la sua vera natura.
- La tensione sale man mano che le domande diventano più incisive e personali, creando un senso di urgenza e mistero. Il Nexus risponde con una miscela di emozioni umane e meccaniche, lasciando Deckard e gli spettatori in suspense su cosa sia realmente, umano o replicante.
- La scena è permeata di un senso di isolamento e introspezione, tipico dello stile neo-noir del film, evidenziando i temi dell'identità, della coscienza e dell'umanità che sono centrali in "Blade Runner".

<https://www.youtube.com/watch?v=OWK6oSbSKKc>



Oggi tutto è mediato da uno schermo.....

Nota reazioni pupillari e microespressioni vengono presentate nel corso nelle prossime lezioni

«Filosofia» biometrica



- Oggi, quasi interamente la nostra esperienza è mediata dalla riproduzione digitale delle immagini e del suono, grazie a dispositivi come i cellulari.
- Questa trasformazione ha reso la componente biologica della nostra iterazione verso gli altri sempre meno frequente (rimanendo però significativa), mentre l'impatto e la validità delle rappresentazioni virtuali continuano a crescere.
- La tecnologia ci permette di condividere, manipolare e reinterpretare il mondo che ci circonda in modi mai visti prima, sfidando la nostra percezione tradizionale della realtà. Questo cambiamento radicale solleva domande importanti sulla verità, l'autenticità e la fiducia nell'era digitale.
- La biometria svolge un ruolo cruciale nel verificare la parte umana nel mondo digitale.
 - A. Attraverso tecnologie come i test di liveness e le tecniche antispoofing, la biometria mira a garantire che le interazioni digitali siano autentiche e connesse a individui reali.
 - B. Allo stesso tempo, il riconoscimento biometrico cerca di acquisire e identificare in modo unico e distintivo le caratteristiche biologiche o comportamentali di ciascun individuo

Adattamento Continuo alle Nuove Sfide per combattere i Deepfake



Innovazione Tecnologica Continua

Le nuove tecnologie emergenti potrebbero fornire strumenti più efficaci per l'analisi e la rilevazione dei deepfake



Apprendimento e Adattamento

I sistemi di rilevamento devono continuare a imparare dai nuovi esempi di deepfake per rimanere efficaci



Ricerca Interdisciplinare e collaborazione tra vari campi

Dalla grafica computerizzata all'intelligenza artificiale, dalla psicologia alla sicurezza informatica - è cruciale per sviluppare metodi di rilevamento robusti



Iniziativa di Sensibilizzazione Globale

Educare il pubblico e i professionisti del settore sui nuovi sviluppi nei deepfake aiuta a creare una comunità più informata e resiliente



Standardizzazione e Legislazione

Lo sviluppo di standard internazionali e l'adozione di legislazioni adeguate possono giocare un ruolo fondamentale nella lotta contro la diffusione dei deepfake

Reato penale dal 2025

Capo V

DISPOSIZIONI PENALI

Art. 26.

Modifiche al codice penale e ad ulteriori disposizioni penali

1. Al codice penale sono apportate le seguenti modificazioni:

a) all'articolo 61, dopo il numero 11-*novies*) è aggiunto il seguente:

«11-*decies*) l'aver commesso il fatto mediante l'impiego di sistemi di intelligenza artificiale, quando gli stessi, per la loro natura o per le modalità di utilizzo, abbiano costituito mezzo insidioso, ovvero quando il loro impiego abbia comunque ostacolato la pubblica o la privata difesa, ovvero aggravato le conseguenze del reato»;

b) all'articolo 294 è aggiunto, in fine, il seguente comma:

«La pena è della reclusione da due a sei anni se l'inganno è posto in essere mediante l'impiego di sistemi di intelligenza artificiale»;

c) dopo l'articolo 612-*ter* è inserito il seguente:

«Art. 612-*quater* (*Illecita diffusione di contenuti generati o alterati con sistemi di intelligenza artificiale*).

— Chiunque cagiona un danno ingiusto ad una persona, cedendo, pubblicando o altrimenti diffondendo, senza il suo consenso, immagini, video o voci falsificati o alterati mediante l'impiego di sistemi di intelligenza artificiale e idonei a indurre in inganno sulla loro genuinità, è punito con la reclusione da uno a cinque anni. Il delitto è punibile a querela della persona offesa. Si procede tuttavia d'ufficio se il fatto è connesso con altro delitto per il quale si deve procedere d'ufficio ovvero se è commesso nei confronti di persona incapace, per età o per infermità, o di una pubblica autorità a causa delle funzioni esercitate».

2. All'articolo 2637 del codice civile è aggiunto, in fine, il seguente periodo: «La pena è della reclusione da due a sette anni se il fatto è commesso mediante l'impiego di sistemi di intelligenza artificiale».

3. All'articolo 171, primo comma, della legge 22 aprile 1941, n. 633, dopo la lettera a-*bis*) è inserita la seguente:

«a-*ter*) riproduce o estrae testo o dati da opere o altri materiali disponibili in rete o in banche di dati in violazione degli articoli 70-*ter* e 70-*quater*, anche attraverso sistemi di intelligenza artificiale».

4. All'articolo 185, comma 1, del testo unico delle disposizioni in materia di intermediazione finanziaria, di cui al decreto legislativo 24 febbraio 1998, n. 58, è aggiunto, in fine, il seguente periodo: «La pena è della reclusione da due a sette anni e della multa da euro venticinquemila a euro sei milioni se il fatto è commesso mediante l'impiego di sistemi di intelligenza artificiale».

Nuovo art. 612-*quater* c.p.

Illecita diffusione di contenuti generati o alterati con sistemi di IA

Chi diffonde, senza consenso, immagini, video o voci falsificati o alterati con IA in grado di indurre in inganno sulla genuinità → **reclusione da 1 a 5 anni** (fino a 6 con aggravanti di **inganno, aggrigotaggio. Fino a 12 anni se abuso di info privilegiate e insider trading.**)


Procedibilità: a querela della persona offesa, ma **d'ufficio** se:

- è collegato ad altro reato perseguibile d'ufficio;
- è commesso contro incapaci, minori, infermi o pubbliche autorità.



Abbiamo visto

- Inverse Turing Test
- Proof of Personhood
- Deep fake
 - Cosa sono
 - A cosa servono (scopi leciti e illeciti)
- Deep fake detection
 - Frame singolo
 - Video
 - Protezione con Challenge-Response
 - Test dei sistemi e Piattaforme



Stato dell'arte 2024

(non all'esame)

- Deepfake Generation and Detection: A Benchmark and Survey
- Gan Pei, Jiangning Zhang, Menghan Hu, Zhenyu Zhang, Chengjie Wang, Yunsheng Wu, Guangtao Zhai, Jian Yang, Chunhua Shen, Dacheng Tao
- Deepfake is a technology dedicated to creating highly realistic facial images and videos under specific conditions, which has significant application potential in fields such as entertainment, movie production, digital human creation, to name a few. With the advancements in deep learning, techniques primarily represented by Variational Autoencoders and Generative Adversarial Networks have achieved impressive generation results. More recently, the emergence of diffusion models with powerful generation capabilities has sparked a renewed wave of research. In addition to deepfake generation, corresponding detection technologies continuously evolve to regulate the potential misuse of deepfakes, such as for privacy invasion and phishing attacks. This survey comprehensively reviews the latest developments in deepfake generation and detection, summarizing and analyzing current state-of-the-arts in this rapidly evolving field. We first unify task definitions, comprehensively introduce datasets and metrics, and discuss developing technologies. Then, we discuss the development of several related sub-fields and focus on researching four representative deepfake fields: face swapping, face reenactment, talking face generation, and facial attribute editing, as well as forgery detection. Subsequently, we comprehensively benchmark representative methods on popular datasets for each field, fully evaluating the latest and influential published works. Finally, we analyze challenges and future research directions of the discussed fields.

- Comments: We closely follow the latest developments in this [https URL](https://arxiv.org/abs/2403.17881)

- Subjects: Computer Vision and Pattern Recognition (cs.CV)

- Cite as: arXiv:2403.17881 [cs.CV]

- (or arXiv:2403.17881v4 [cs.CV] for this version)

- <https://doi.org/10.48550/arXiv.2403.17881>

- Focus to learn more

Noname manuscript No.
(will be inserted by the editor)

Deepfake Generation and Detection: A Benchmark and Survey

Gan Pei¹ · Jiangning Zhang¹ · Menghan Hu¹ · Zhenyu Zhang² ·
Chengjie Wang² · Yunsheng Wu³ · Guangtao Zhai¹ · Jian Yang² ·
Chunhua Shen⁴ · Dacheng Tao⁵

Received: date / Accepted: date

Abstract Deepfake is a technology dedicated to creating highly realistic facial images and videos under specific conditions, which has significant application potential in fields such as entertainment, movie production, and digital human creation, to name a few. With the advancements in deep learning, techniques primarily represented by Variational Autoencoders and Generative Adversarial Networks have achieved impressive generation results. More recently, the emergence of diffusion models with powerful generation capabilities has sparked a renewed wave of research. In addition to deepfake generation, corresponding detection technologies continuously evolve to regulate the potential misuse of deepfakes, such as privacy invasion and phishing attacks. This survey comprehensively reviews the latest developments in deepfake generation and detection, summarizing and analyzing current state-of-the-arts in this rapidly evolving field. First, we unify task definitions, comprehensively introduce datasets and metrics, and discuss developing technologies. Then, we discuss the development of several related sub-fields and focus on researching four representative deepfake fields: face swapping, face reenactment, talking face generation, and facial attribute editing, as well as forgery detection. Subsequently, we comprehensively benchmark representative methods on popular datasets for each field, fully evaluating the latest and most influential published works. Finally, we analyze the challenges and future research directions of the discussed fields. We closely follow the latest developments in this project.

Keywords Deepfake Generation · Face Swapping · Face Reenactment · Talking Face Generation · Facial Attribute Editing · Forgery detection · Survey

1 Introduction

Artificial Intelligence Generated Content (AIGC) garners considerable attention [227] in academia and industry. Deepfake generation, as one of the important technologies in the generative domain, gains significant attention due to its ability to create highly realistic facial media content. This technique transitions from traditional graphics-based methods to deep learning-based approaches. Early methods employ advanced Variational Autoencoder [136, 239, 252] (VAE) and Generative Adversarial Network (GAN) [125, 138] techniques, enabling seamlessly realistic image generation, but their performance is still unsatisfactory, which limits practical application. Recently, the diffusion structure [16, 77, 166] has greatly enhanced the generation capability of images and videos. Benefiting from this new wave of research, deepfake technology demonstrates potential value for practical applications and can generate content indistinguishable from real ones, which has further attracted attention and is widely applied in numerous fields [11], including entertainment, movie production, online live broadcasting, and privacy protection, etc.

Deepfake generation can generally be divided into four mainstream research fields: 1) Face swapping [6, 206, 263] is dedicated to executing identity exchange between two person images; 2) Face reenactment [17, 67, 140] emphasizes transferring source movements and poses; 3) Talking face generation [170, 169, 328] focuses