



L21

Spoofing e antispoofing Adversarial Attacks Detection Volto (2D e 3D)

Fabio Scotti

Università degli Studi di Milano



fabio.scotti@unimi.it

OUTLINE

Adversarial attacks

Spoofing e antispoofing

- Approccio classico e approccio moderno (vettori di attacco)
- Adversarial Attacks Detection
 - Evasione
 - Avvelenamento
 - Estrazione
 - Inferenza
- Spoofing e antispoofing
 - Volto 2D
 - Volto 3D




Vettori di attacco: Framework Classico

Il framework mentale tradizionale si basa su due pilastri fondamentali:

a) Attacchi al sistema stesso

- Riguardano l'infrastruttura fisica o digitale.
- Esempio: attacchi DoS, manomissione hardware, violazioni della rete




Tipi di vettori di attacco comuni

Vettori di attacco: Framework Classico

Il secondo pilastro:

b) Attacchi sugli ingressi

- Presentation Attack Devices (PAD)
- Perturbazione degli ingressi (Attacchi avversari)



From ISO/IEC 30107-1, inspired by figure by Nalini Ratha from 2001 and Standing Document 11 of ISO/IEC JTC1 SC37.

Vettori di attacco: Framework Classico



USB baiting

Vettori classici (vedi altri insegnamenti)

1 Phishing:

- Ingannare gli utenti per ottenere credenziali di accesso.
- Brute Force: Tentativi ripetuti di indovinare password o codici.
- Exploitation: Utilizzo di vulnerabilità note per accedere al sistema.

2. Rete, Man-in-the-Middle (MITM):

- Intercettazione e alterazione di comunicazioni tra due parti.
- Denial of Service (DoS) e Distributed DoS (DDoS): Sovraccaricare un sistema per renderlo non operativo.
- Packet Sniffing: Intercettazione di dati sensibili trasmessi in rete.

3. Fisici / Hardware Compromesso:

- Inserimento di dispositivi fisici, come chiavette USB infette.
- Tampering: Alterazione fisica dei componenti del sistema.
- Accesso Diretto: Uso di porte non protette o dispositivi incustoditi.

4. Software Malware:

- Software malevolo come virus, worm, trojan e ransomware.
- Zero-Day Exploits: Attacchi basati su vulnerabilità sconosciute ai produttori.
- Backdoor: Accesso segreto installato intenzionalmente o tramite malware.

Vettori di attacco: Framework Classico

Vettori classici (vedi altri insegnamenti)

5. Insider

- Accesso di dipendenti malintenzionati: Uso delle credenziali legittime di un insider.
- Social Engineering: Manipolazione psicologica di utenti per ottenere informazioni sensibili.
- Negligenza: Errori non intenzionali che compromettono il sistema.

6. Economici

- Frodi finanziarie: Manipolazione di transazioni o bilanci.
- Estorsione: Richiesta di riscatto per informazioni o accesso (es. ransomware).
- Alterazione di incentivi: Deviazione di flussi monetari.

7. Data Breach

- Esfiltrazione non autorizzata di dati sensibili.
- Data Poisoning: Manipolazione dei dati di training nei modelli di machine learning.
- Data Manipulation: Alterazione dei dati per influenzare decisioni o operazioni.

Attacchi: Framework **Avanzato**


Il nuovo framework mentale integra i vettori classici con nuove **minacce derivanti dall'uso intensivo di AI** e risorse esterne.

Nuove problematiche da affrontare

- **Modelli malintenzionati (Malicious)**
 - modelli creati o inquinati per favorire decisioni errate.
 - Esempio: bias intenzionali in modelli di raccomandazione o predizione.
- **Sorgenti esterne di dati e modelli**
 - Furto, alterazione o inserimento di dati e modelli provenienti da terze parti.
 - Esempio: un dataset compromesso utilizzato per addestrare un modello.

Riassumendo

- In un framework moderno si possono prevedere attacchi non solo sugli ingressi e sul sistema stesso, ma, se vengono impiegati modelli di ML, anche sul **modello stesso e sui dati per allenarlo**





Adversarial Attacks (parte 2)

DETECTION

Cambiamenti impercettibili effettuati sui sample biometrici per produrre effetti importanti ed errori sui sistemi di AI.

Come possiamo accorgerci dell'attacco?

Come rendere le reti immuni?

Memo

L'idea base

Attacker

Perturbations



Target



Con la perturbazione si
cambia la classificazione

Clean

Perturbation

Adversarial



Female

Male

Con la perturbazione si
aumenta artificialmente la
similitudine

Adversarial attacks and images

- **Adversarial attack**


consiste nel **modificare** in modo sottile un input originale del classificatore, in modo tale che le modifiche risultino quasi **impercettibili** all'occhio umano.

- **Adversarial image**


è un'immagine che è stata **leggermente modificata** con l'obiettivo di ingannare il classificatore, cioè di farla classificare in modo errato.



Schema generale degli Adversarial Attacks



Schema generale degli Adversarial Attacks




Perché le DNN sono vulnerabili agli attacchi avversari?

- Le DNN sono vulnerabili agli attacchi avversari perché
 - sono altamente **non lineari**
 - **sensibili a piccole perturbazioni nello spazio di input**
Cosa vuole dire? → ad una specifica variazione piccola rispondono con grandi variazioni delle uscite
- L'attaccante può sfruttare le **informazioni del gradiente della DNN** per creare esempi avversari che sono impercettibili agli occhi umani, ma possono drasticamente alterare l'output della DNN
- Inoltre, gli attacchi avversari **possono trasferirsi attraverso diversi modelli e architetture**, il che significa che un attacco che funziona su una DNN può anche funzionare su un'altra con una struttura o dati di addestramento diversi.

Adversarial attack VS deeplearn

- In 2013, [Szegedy et al.](#) introduced one of the first **adversarial examples**, inputs that appear normal to humans but trick algorithms into confidently outputting wrong predictions.




Two pictures of snails, but one looks like a mitten to Inception V4,
to a deeplearn image recognition model from Google

Example of Adversarial attacks: the MNIST dataset


Adversarial Examples




Adversarial Reconstructions



Dataset: MNIST
Network: LeNet architecture trained on 60000 MNIST samples



Design the minimum distortion




The colored curves represent the boundaries for decision-making of a well-trained machine learning model (e.g., a neural network image classifier).

Choice of the sample to be distorted (cont..)



Chihuahua or muffin?


...but the concept of similarity for the human brain is not equivalent to metrics in deep learning networks.




Come Funzionano gli Attacchi Avversari?

- Esiste una vasta varietà di diversi attacchi avversari che possono essere utilizzati contro i sistemi di machine learning
 - sistemi di deep learning
 - modelli tradizionali di machine learning come le Macchine a Vettori di Supporto (SVM) e la regressione lineare.
- La maggior parte degli attacchi avversari mira solitamente a deteriorare le prestazioni dei classificatori su compiti specifici, essenzialmente per "ingannare" l'algoritmo di machine learning.

Uso del gradiente



- Come una leva, si cerca di creare una minima variazione in ingresso, ma che fa compiere nello spazio delle feature interno un salto grande abbastanza da spostare la classificazione.
- Processo iterativo
 - $\text{new_weights} = \text{old_weights} - \text{learning_rate} * \text{gradients}$
 - $\text{new_pixels} = \text{old_pixels} + \text{epsilon} * \text{gradients}$



White or black box attacks

White box attacks

- The attacker has access to the model's parameters
 - e.g. the system is using CNN that is a public

• Black box attacks

- The attacker has no access to these parameters
 - uses a different model or no model at all to generate adversarial images with the hope that these will transfer to the target model.


• Gray box attacks

- Some information about the model is known (e.g. finetuning of a public model)

Attacchi fisici a modelli black box



«switch»




Con il termine «fisico» si intende un attacco con un artefatto al sensore (uno schermo davanti alla telecamera, un oggetto sul volto ecc.)


Figure 1: Demonstration of a black box attack (in which the attack is constructed without access to the model) on a phone app for image classification using physical adversarial examples. We took a clean image from the dataset (a) and used it to generate adversarial images with various sizes of adversarial perturbation ϵ . Then we printed clean and adversarial images and used the TensorFlow Camera Demo app to classify them. A clean image (b) is recognized correctly as a “washer” when perceived through the camera, while adversarial images (c) and (d) are misclassified. See video of full demo at https://youtu.be/zQ_uMenoBCk.

Non-targeted Adversarial Attack

- A noise addition aiming to trick the model into an incorrect prediction, without specifying what that incorrect prediction.
- Examples:
 - from a black-listed voice to an unknown user
 - from an image of a face that is not considered as a face and processed



(a) noises



(b) voice+noises



Esempio nella visione

La macchina con adesivi mimetici ad-hoc
è stata erroneamente identificata come un "dolce".



CAMOU: Learning Physical Vehicle Camouflages to Adversarially Attack Detectors in the Wild



Esempio della visione



Nome del metodo:
Robust Physical Perturbations (RP2) “to
generate physical perturbations for physical-
world”

Funzionante anche a scale
diverse e diversi angoli...

Distance/Angle	Subtle Poster	Subtle Poster Right Turn	Camouflage Graffiti	Camouflage Art (LISA-CNN)	Camouflage Art (GTSRB-CNN)
5' 0°					
5' 15°					
10' 0°					
10' 30°					
40' 0°					
Targeted-Attack Success	100%	73.33%	66.67%	100%	80%



Targeted Adversarial Attack

- use small amounts of imperceptible noise to transform the output of the recognition in a desired class.

Examples:

- From impostor voice to a specific genuine voice
- From a impostor face to the most similar genuine in the DB
- Speech to text case: the audio that should be interpreted as “I’m taking a walk in Central Park” into random gibberish, complete silence, or even a sentence like “Call 911 immediately!”
- ...a more dangerous attack that tricks the model into producing a particular target prediction.

Face Identity concealing via adversarial images



Dataset: 1070-W dataset



Network: Faster R-CNN

Compression noise


- La supposizione che il rumore di compressione (per esempio applicando un JPEG) non è sempre vera.
- Per valori normali di compressione, anche il 99-95% dei volti possono non essere detezionati




0.5%-5%
face
detection!



Adversarial attacks



Esempio per lo speech to text



Capiamo bene la rilevanza di questi attacchi ora che i sistemi di AI stanno diventando «agentificati», ovvero in grado di eseguire compiti per noi di alto livello (e.g. acquisti, email)!!

Alcuni esempi di exploit

The screenshot shows the top of The Verge website. The main headline is "Burger King's new ad forces Google Home to advertise the Whopper". Below it, there are two more headlines: "Amazon's Alexa heard her name and tried to order up a ton of dollhouses" and "People Are Complaining That Amazon Echo Is Responding to Ads on TV".

THE VERGE TECH · SCIENCE · CULTURE · CARS · REVIEWS · LONGFORM · VIDEO · MORE · f · t · s · u · q

HOME \ TECH

Burger King's new ad forces Google Home to advertise the Whopper

OUR PICKS · LATEST · POPULAR · QUARTZ · OBSESSIONS

IMPULSE BUYING

Amazon's Alexa heard her name and tried to order up a ton of dollhouses

People Are Complaining That Amazon Echo Is Responding to Ads on TV


OVEREAGER SPEAKER Man's Amazon Echo accidentally ordered cat food after overhearing Alexa ad

'South Park' Episode Triggers Viewers' Amazon Alexa and Google Home

Adversarial attacks

- Molte tecniche di face recognition sono dotate di moduli iniziali di detezione del corpo/volto basati su reti neurali profonde (Deep Learning NNs)
- L'attacco consiste nell'indossare indumenti (abiti, cappelli, casco, ...) che impediscono la rilevazione del corpo/volto
- Esistono aziende che si occupano di questo (Cap_able, dal 2022)

<https://www.capable.design/>




4 tipi

di attacco avversario

Evasione, Avvelenamento, Estrazione, Inferenza


4 tipi principali di attacco avversario

- **Evasione**
Attacchi che modificano l'input per influenzare il modello. Ad esempio, aggiungendo modifiche a immagini mediche per influenzare la classificazione
- **Avvelenamento**
Attacchi che modificano i dati di addestramento per aggiungere un backdoor. I modelli addestrati senza rendersene conto hanno backdoor che controllano i modelli
- **Estrazione**
Attacchi che rubano un modello proprietario. Ad esempio, gli attacchi possono interrogare regolarmente un modello per estrarre informazioni preziose
- **Inferenza**
Attacchi che ottengono informazioni su dati privati. Ad esempio, un attacco può derivare proprietà dei dati di addestramento del modello fino a identificare singole voci di dati





Evasion Attacks

- Gli attacchi di evasione sono i tipi di attacchi più diffusi e più studiati. L'attaccante manipola i dati durante il dispiegamento per ingannare i classificatori precedentemente addestrati
- Poiché vengono eseguiti durante la fase di dispiegamento (deployment), sono i tipi di attacchi più pratici e i più utilizzati negli scenari di intrusione e di malware
- Gli attaccanti spesso tentano di evitare il rilevamento offuscando il contenuto del malware o delle email spam. Pertanto, i campioni vengono modificati per evitare il rilevamento poiché vengono classificati come legittimi senza richiedere di influenzare direttamente i dati di addestramento come in altri approcci




Poisoning Attacks

("backdoor")



- L'attaccante influenza i dati di addestramento o le loro etichette (con una contaminazione) per causare un calo delle prestazioni del modello durante il suo utilizzo.
- Poiché i sistemi di ML possono essere riaddestrati utilizzando dati raccolti durante il funzionamento, un attaccante può avvelenare i dati iniettando campioni malevoli durante il funzionamento, che successivamente disturbano o influenzano il riaddestramento.
- Nota: sempre più sistemi deep vengono allenati prendendo immagini e label in rete senza un controllo completo della provenienza o della loro attendibilità (vedi chatGPT...)



Backdoor / poisoning integrity attacks place mislabeled training points in a region of the feature space far from the rest of training data. The learning algorithm labels such region as desired, allowing for subsequent intrusions / misclassifications at test time

La presenza del pezzetto giallo al centro è un «trigger» che provoca il cambio di classificazione



Estrazione

- L'obiettivo dell'attacco è sondare il modello di machine learning con diversi dati di input e valutare l'output
- Un attacco di inferenza può essere effettuato anche se l'attaccante ha informazioni parziali sui dati di addestramento e ipotizza i dati mancanti fino a quando l'algoritmo raggiunge le massime prestazioni
- In un attacco di estrazione del modello, un avversario ruba una copia di un modello di machine learning distribuito in remoto, avendo accesso a previsioni oracolari.
- Viene prodotto facendo richieste al modello bersaglio con input per estrarre quante più informazioni possibili e con l'insieme di input e output addestrare un modello chiamato modello sostitutivo.
- Estrarre il modello è difficile, l'attaccante ha bisogno di una grande capacità di calcolo per riaddestrare il nuovo modello con accuratezza e fedeltà, e il modello sostitutivo equivale ad addestrare un modello da zero.





Figure 6: An image recovered using a new model inversion attack (left) and a training set image of the victim (right). The attacker is given only the person's name and access to a facial recognition system that returns a class confidence score [19]


Oltre a replicare il modello di face authentication interrogando il sistema biometrico con delle facce da autenticare, qui miglioro l'immagine di un partecipante facendo crescere il matchscore

Estrazione




Inferenza

- Gli attacchi di inferenza sono progettati per invertire il flusso di informazioni di un modello di machine learning.
- Questo tipo di attacco consente a un avversario di acquisire conoscenze sul modello che non erano intese per essere condivise.
- Ciò è particolarmente preoccupante perché viola la privacy e la sicurezza degli individui e dei sistemi coinvolti.
- Proteggere i modelli di machine learning dagli attacchi di inferenza può essere difficile. Le tecniche di difesa includono l'incremento della privacy dei dati, come l'uso di tecniche di anonimizzazione o di privacy differenziale, e la modifica dei classificatori per ridurre la loro capacità di rivelare informazioni su dati specifici.



Esempio: nel dicembre 2023 un team di ricercatori di Google DeepMind sia riuscito a far rivelare a ChatGpt le informazioni personali di decine di persone semplicemente chiedendogli di ripetere all'infinito la stessa parola.



La persona X è all'interno dei dati pubblicati?

Come ci difendiamo?

In letteratura e nella pratica ci sono 3 approcci


Approccio 1
Intelligence/buona pratica



Approccio 2:
Addestramento Avversario



Approccio 3
**Regolarizzazione
dell'apprendimento**



Cose da tenere conto per proteggersi...

Approccio 1 «intelligence»



- Gli avversari tipicamente necessitano di una forma di accesso al tuo modello di machine learning o ai suoi dati di addestramento per eseguire un attacco.
- Ma assumendo che il tuo modello sia ospitato in un ambiente a cui un avversario non può accedere, come possono avvenire gli attacchi ai flussi di lavoro di ML?
 - In termini più pratici, come può un avversario ottenere accesso al tuo modello e ai dati di addestramento?



Cose da tenere conto per proteggersi...

Approccio 1 «intelligence»

Ecco solo alcuni dei casi in cui gli avversari possono ottenere accesso al tuo flusso di lavoro e ai dati:

1

Stai utilizzando un dataset da una fonte non verificata.

- Un avversario potrebbe avvelenare i dati e pubblicarli da qualche parte per squadre ignare da utilizzare. I dataset da fonti inaffidabili o non verificati hanno un rischio maggiore di essere compromessi.



Cose da tenere conto per proteggersi...

Approccio 1 «intelligence»

Ecco solo alcuni dei casi in cui gli avversari possono ottenere accesso al tuo flusso di lavoro e ai dati:

2

Stai utilizzando un

modello da una fonte non verificata.

- Similmente ai dati di addestramento, gli avversari possono pubblicare modelli affinché le vittime li utilizzino.
- Possono poi utilizzare la loro conoscenza del modello per eseguire attacchi su di esso. I modelli da fonti sospette potrebbero anche essere pre-addestrati su dati avvelenati.



Cose da tenere conto per proteggersi...

Approccio 1 «intelligence» (cont.)

3

Stai utilizzando un modello disponibile pubblico.

Supponiamo che tu stia utilizzando un modello NLP di Hugging Face.

- Es. I modelli di Hugging Face sono disponibili a chiunque. Un avversario potrebbe analizzare un modello pubblicamente disponibile e utilizzare la sua conoscenza per attaccare altri modelli simili utilizzati da altre squadre.
 - In effetti, gli avversari non necessitano di avere esattamente lo stesso modello che hai tu, la conoscenza di un modello che svolge lo stesso compito del tuo può essere sufficiente per un attacco.

Cose da tenere conto per proteggersi...

Approccio 1 «intelligence» (cont.)



4

Un avversario ha accesso al tuo flusso di lavoro di ML


(lo hai pubblicato?!)

- Se un insider malintenzionato ottiene accesso al tuo flusso di lavoro (sfruttando la sua posizione all'interno dell'organizzazione), ad esempio
 - può acquisire conoscenze approfondite sulla sua architettura, pesi e dati di addestramento.
 - Potrebbero anche conoscere le misure che utilizzi per proteggere il tuo modello, rendendo gli insider malintenzionati probabilmente la maggiore minaccia per la sicurezza dei flussi di lavoro di ML.

Questa non è una lista esaustiva, ma ti aiuta a capire come il tuo modello o i dati di addestramento potrebbero essere compromessi.




Approccio 2 per difendersi dagli Adversarial Attacks Inserire Dati nel Training!



Il metodo di difesa più noto è l' "addestramento avversario", in cui uno sviluppatore corregge le vulnerabilità addestrando il modello di machine learning su esempi avversari.

Approccio 3 per difendersi dagli Adversarial Attacks

Regularizzazione




- Le tecniche di regularizzazione dell'apprendimento per i DNN sono importanti per la difesa dagli attacchi avversari perché possono aiutare la rete a resistere o a recuperare dalle perturbazioni avversarie.
- **Weight Decay**
 - aggiunge un termine di penalità alla funzione di **perdita che è proporzionale alla grandezza dei pesi** della rete, il che può ridurre l'overfitting
- **Dropout**
 - **elimina casualmente alcune unità o connessioni** nella rete durante l'addestramento, creando una forma di apprendimento collettivo che aumenta la diversità e la ridondanza
- **Batch Normalization**
 - I parametri di uno strato influenzano la distribuzione degli input dello strato successivo, rendendo necessario un continuo aggiustamento dei tassi di apprendimento e una inizializzazione cauta dei pesi.
 - La batch normalization **normalizza gli input di ogni strato nella rete**, riducendo lo spostamento covariato interno e rendendola più robusta alle perturbazioni avversarie.

Attacchi sugli ingressi e ISO 30107

DeepFake, Attacchi sul sensore

Fake news, contents, accounts



- Nuovo livello: generazione di contenuti provocatori e indirizzati sempre più realistici di fini
 - Commerciali (click bait)
 - Politici
 -
- Generazione di
 - volti noti (in filmati, con audio) in contesti fake
 - account completamente fake con dati verosimili

Questo argomento ci fa rivedere in modo completamente diverso le tecnologie di generazione sintetica dei tratti biometrici attuali

Biometric Systems Vulnerability



According to ISO terminologies, the attacks are divided into

- **Zero-effort**

- imposter testing—“inter-individual” testing is used to estimate false match rate and false accept rate (FMR and FNMR, FAR and FRR)

- **Non-zero effort**

- spoofs or artefacts are created to test system robustness to recognizing presentation attacks and are used to estimate **spoof performance metrics** (APCER, APMR)



Metriche attacchi Non-zero effort

Non si usano FAR e FRR classici, ma APCER e BPCER

APCER

- Attack Presentation Classification Error Rate
- Misura la **vulnerabilità agli attacchi**.

$$APCER = \frac{\text{Attacchi classificati come genuini}}{\text{Totale attacchi}}$$


Metriche attacchi Non-zero effort

BPCER

- Bona Fide Presentation Classification Error Rate
- Misura l'impatto sull'usabilità.


$$BPCER = \frac{\text{Utenti genuini classificati come attacco}}{\text{Totale genuini}}$$

Biometric Systems Vulnerability (cont.)




(*) Function creep:
the gradual widening of the use of a technology or system beyond the purpose for which it was originally intended, especially when this leads to potential invasion of privacy

Biometric systems vulnerability to adversarial attacks




Un Sistema biometrico e' solo un particolare tipo di Sistema informatico.
Pertanto si hanno sempre le possibilita' di attacco "classiche"
che vengono studiate nel Corso di laurea.

Adversary attacks: DIRECT vs INDIRECT




INDIRECT Attacks

- From the **inside** of the system:
 - bypassing the feature extractor or the comparator
 - manipulating the biometric references in the biometric reference database
 - exploiting possible weak points in communication channels
- ...




Examples of **INDIRECT** Attacks

- Substitution in the DB, Override the biometric final output, tampering, intercept, ...



DIRECT Attacks

- Direct attacks (presentation/spoofing attacks) are performed at the sensor level
 - not replaced
 - nor tampered.





Presentation Attacks

Definitions, glossary and examples

Presentation attacks

ISO standard *IEC 30107-1:2016(E)*

- **Presentation Attack (PA)**

- *Presentation to the biometric capture subsystem with the goal of interfering with the operation of the biometric system*

- **Presentation Attack Detection (PAD)**

- *Automated determination of a presentation attack*

- **Presentation Attack Instrument (PAI)**

- Biometric characteristic or **object** used in a presentation attack

- **Normal (Bona Fide) Presentation**

- interaction of the biometric capture subject and the biometric data capture subsystem in the fashion intended by the policy of the biometric system (not a PA)

Essere compliant ISO 30107



Cosa vuole dire quando una azienda è compliant alla ISO 30107?

Il sistema è stato testato con:

- Campioni genuini (bona fide)
- Artefatti di attacco
(presentation attack instruments)
- Protocollo di prova strutturato
e con metriche specifiche


Impostors

- **Impostor** (Definitions in ISO/IEC 2382-37)
 - *subversive biometric capture subject who attempts to being matched to someone else's biometric reference*
- **Actions:**
 - Impersonation attack
(aims to positive access in 1:1 or 1:N)
 - *Finding a look-a-like*
 - *Making appearance similar to the reference*
 - *Artefact presentation*
 - *Fingerprint: gummy fingers*
 - *Face: make-up adversary attack*
 - *Iris: printed contact lens*
 - ...



Application of cosmetics

A relevant
discrepancy of
the same
identity can be
observed




...making appearance similar to the reference

Makeup alterations can indeed compromise the accuracy of a biometric system



subject #1
before makeup



subject #1
after makeup



targets



Identity concealer

- **Identity concealer** (Definitions in ISO/IEC 2382-37)
 - *subversive biometric capture subject who attempts to avoid being matched to their own biometric reference*
- Evasion from recognition (aims to negative in 1:1 or 1:N, watchlist application)
- Far to from standard pose or position/expression
- Avoiding detection or segmentation




DOI: 10.5772/19159

Example of Identity concealing: camouflage from face detection




Esempi artistici



Makeup that contrasts with your skin tone in unusual tones and directions; obscure the nose-bridge area; partially obscure one of the ocular regions; obscuring the elliptical shape of a head; developing an asymmetrical look.

Grigori Bakunov




Identity concealing



Hiding in plain sight:
the activists camouflaging
faces to beat surveillance

Club began last year as a response to the installation, later scrapped, of technology at King's Cross, London. "It was very annoying and made us quite angry. There are a lot of issues camera is you can walk differently, but if you're not aware of where it is you cannot hide your gaze." Laurie Smith, a principal researcher at Nesta, the innovation charity, said



Non-conformant presentation

Lo scopo è quello di bypassare il riconoscimento biometrico ingannando il sensore e passare alla autenticazione classica più facilmente attaccabile




Apple Face ID technology is working with polarized lens but some lens block IR radiation preventing a correct identification





Fingerprint sensors are working poorly if the fingertip is misplaced, rolled too much or wet/dirt

Driving license
released in
Florida



Occlusions

- The face can be occluded by beard, sunglasses or clothes (in enrollment or verification)
 - Do not accept samples if the covered area does not guarantee the accuracy certified for the system



Liveness detection methods
are defined to be a sub-set of
Presentation Attack Detection
(PAD) methods

Glossary (cont.)

Liveness

- the quality or state of being alive, made evident by
 - anatomical characteristics (e.g. skin or blood absorption of illumination),
 - involuntary reactions (small movement of the eyes)
 - physiological functions (e.g. iris reaction to light, heart activity-pulse),
 - voluntary reactions or subject behaviors (e.g., biometric presentation in response to a directive cue).

Liveness detection

- detection of anatomical characteristics or involuntary or voluntary reactions, in order to determine if a biometric sample is being captured from a living subject present at the point of capture

Glossary (cont.)




Artefact:

- artificial object or representation presenting a copy of biometric characteristics or synthetic biometric patterns

Spoof:

- to subvert a system by presentation of an artefact

Presentation Attack Instruments



Professional makeup

- A combination of makeup and-or artificial masks made of artificial skin can effectively spoof face recognition systems
 - Possible countermeasures involves thermographic or multiband techniques based on non-visible light frequencies to detect artificial components on the real skin.



“Fascinazione” degli attacchi


I media rappresentano gli attacchi al sistema biometrico in modalità estremamente non realistica... la realtà è diversa.



Demolition Man (1993)

Genuine vs Attacks in real life

GENUINE



ATTACKS



PHOTO

VIDEO

3D MASK

OTHERS

Antispoofing Livelli ISO

<https://www.iso.org/standard/67381.html>

Artifact Level	Description	Example
Level 1 (A) (Spoof Bounty Avail)	Hi-res paper & digital photos, hi-def challenge/response videos and paper masks. Beware: iBeta Lab Tests DO NOT include digital deepfake puppets, but FaceTec's Spoof Bounty DOES include deepfake puppets.	
Level 2 (B) (Spoof Bounty Avail)	Commercially available lifelike dolls, and human-worn resin, latex & silicone 3D masks under \$300 in price.	
Level 3 (C) (Spoof Bounty Avail)	Custom-made ultra-realistic 3D masks, wax heads, etc., up to \$3,000 in creation cost. *No Lab Testing Avail	

Epidermide e volto simulati

- Nel campo delle protesi e dei materiali sintetici che emulano il corpo umano sono stati fatti grandi passi avanti
- 3D Printed Latex Masks



Sample images of ThatsMyFace and Real-F Mask

Riferimento: progetto EU TABULA RASA

Fornitori di dati e maschere (per test)

iBeta Quality Assurance

è un **laboratorio indipendente di testing** che testa i sistemi secondo ISO/IEC 30107 cioè lo standard internazionale che definisce come valutare il PAD (Presentation Attack Detection)

Un'azienda manda il proprio sistema di liveness.


iBeta:

- Prepara attacchi (foto, replay, maschere, silicone, ecc.)
- Li presenta al sistema
- Registra:
 - quanti attacchi passano (APCER)
 - quanti genuini vengono bloccati (BPCER)



Axon Labs

- **vende dataset** progettati per:
- allenare modelli di liveness
- fare pre-testing
- preparare un sistema prima di andare da iBeta



Real life spoofing: silicon masks

- Conrad Zdzierak, 30, pleaded guilty in Ohio (USA) to one count of aggravated robbery and five counts of robbery in a plea deal with prosecutors.




Zdzierak's masked resemblance to the black man who was initially arrested was so similar that some witnesses even identified a photo of the black man as the one who robbed them.

The Marc Terrance George's case

- TUCSON, Ariz. – Marc Terrance George, 41, of Jamaica, was sentenced by U.S. District Judge Cindy K. Jorgenson to 13 months in prison, to be followed by deportation, after he pleaded guilty on February 27, 2006 of illegal entry after deportation.
- **George attempted to enter the U.S. illegally on September 24, 2005** through the Nogales, Ariz. Port of Entry during which time U.S. Customs and Border Protection officers noted that his fingerprints had been surgically replaced with skin from his feet.
- "This case demonstrates what extraordinary and drastic measures people will take to enter our country illegally," stated U.S. Attorney Paul K. Charlton.



Types of Presentation Attacks



Artificial

- **Complete**
 - gummy finger, video of face
- **Partial**
 - glue on finger, sunglasses, artificial/patterned, contact lens

Human

- **Lifeless**
 - cadaver part, severed finger/hand
- **Altered**
 - mutilation, surgical switching of fingerprints between hands and/or toes
- **Non-Conformant**
 - facial expression/extreme, tip or side of finger
- **Coerced**
 - Unconscious, under duress or menace
- **Conformant**
 - zero effort impostor attempt

Coerced: unconscious, under duress or menace



....sometime
adversarial attacks
can be simpler
then expected
by designers



ANTI-SPOOFING

Metodi generali

Rilevamento dell'attacco (dentro o fuori il Sistema biometrico)

Interno

**Through a biometric
System**

Artefact Detection

Liveness Detection

Alteration Detection

Non-conformance Detection

Coercion Detection

Obscuration Detection

Esterno

**Through system
security policies**

Failed attempt detection
counter


Geographic

Temporal

Video Surveillance

Stessa identità in due
posti contemporaneamente


Schema generale di antispoofing




FR = Face Recognition

Studiamo le variazioni reali delle immagini VS quelle negli attacchi

Real pose, scale, expression and lighting differences
(SiW dataset)




Presentation Attacks with different inputs



Approcci multibanda

Maggiori tipi di immagine possiamo sfruttare migliore sarà la capacità di individuare un attacco




1) Observations on infrared images


- Printed images or images showed on a screen cannot be used to attack near IR cameras



Lumia 1020



School Portrait




Surface Pro 3

2) Composite approaches: Visible + NIR + 3D

- Using devices able to acquire information on the 3D volume of objects (e.g., Kinect and RealSense) can improve the anti-spoofing capabilities

Data obtained
using a RealSense R200




3D mesh composed of 250.000 triangles

3) Attack based on color images: image histogram analysis



Examples of attacks to a phone:
printed image and screen


The estimation is performed by
analyzing the shape the
histogram of every color




3) Attack based on images and display: Moiré effect

Images acquired by framing printed pictures or screens present a distinctive color pattern

They can be observed in the captured image or applying the Fourier transform



Portion of the image Lena acquired using an iPhone 4 framing the screen of a 13" Macbook Pro



Periodic peak pattern
in the spectrum
= Moiré pattern
→ Probably fake!



4) 3D analysis using a 2D sensor

- Using a single camera, it is possible to apply the shape from motion technique
- Eg.: ZoOm from facetechnology → move the phone close to the face




NORMAL, NO DISTORTION



FISH-EYE, PERSPECTIVE DISTORTION




5) Flusso ottico e antispoofing



5) Flusso ottico e replay/presentation attack


Nei replay/presentation attack semplici con fotografie il flusso ottico è più omogeneo e uniforme

I micro movimenti del volto rispetto all'ambiente vengono rilevati.



6) Uso di sensori ad altissima framerate per catturare le dinamiche del tratto

Tecnologie simili a questa introdotta nelle prime lezioni nel corso stanno portando a grandi miglioramenti nell'antispoofing come ad esempio la compressione del dito durante acquisizione, pulsazioni cardiache nel volto, ecc...



120 Frame per second for 19.3M pixels

960 fps FHD (1,920 x 1,080)
super slow motion video

7) Challenge-response

- 1) The system challenges the user with **some random instructions**,
- 2) the **response is checked** to validate whether the instructions were followed.

- Examples

- **Face**: the system challenges the user to **turn his head** and analyses the head movement direction verifying whether the user turned his head according to the randomly challenged direction.
- **Voice**: the system challenges the user to say a **specific list of words**.



Say «Open Sesame»

Antispoofing: ISO di riferimento

<https://www.iso.org/standard/67381.html>

- **ISO/IEC 30107-3:2017**

- **Information technology — Biometric presentation attack detection — Part 3: Testing and reporting**

- Principles and methods for **performance assessment** of presentation attack detection mechanisms;
- **Reporting** of testing results from evaluations of presentation attack detection mechanisms;
- Classification of known **attack types** (in an informative annex)

Artifact Level	Description	Example
Level 1 (A) (Spoof Bounty Avail)	Hi-res paper & digital photos, hi-def challenge/response videos and paper masks. Beware: iBeta Lab Tests DO NOT include digital deepfake puppets, but FaceTec's Spoof Bounty DOES include deepfake puppets.	
Level 2 (B) (Spoof Bounty Avail)	Commercially available lifelike dolls, and human-worn resin, latex & silicone 3D masks under \$300 in price.	
Level 3 (C) (Spoof Bounty Avail)	Custom-made ultra-realistic 3D masks, wax heads, etc., up to \$3,000 in creation cost. *No Lab Testing Avail	

Esempio di livelli di attacco nel volto



Antispoofing per il volto 2D

Epidermide e volto simulati

- Nel campo delle protesi e dei materiali sintetici che emulano il corpo umano sono stati fatti grandi passi avanti
- 3D Printed Latex Masks



Sample images of ThatsMyFace and Real-F Mask

Riferimento: progetto EU TABULA RASA


Possibili approcci

Si applicano i concetti generali appena visti

- Studio istogrammi colori
- Controllo in IR
- VIS+IR (fusione e/o congruenza)
- Ricerca dei Moirè + studio frequenza per pattern di stampa
- Si possono aggiungere metodi specifici del volto
 - 2D statico (frame singolo)
 - 2D(t) (video)

Approccio deep generalista singolo frame


- Usando i DB pubblici di attacchi o immagini reali si allenano delle reti a trovare nei dettagli delle immagini la classificazione real/fake
- Approccio sempre possibile, ma a bassa explainability e tuning.



Possibili controlli: battito delle palpebre



(a) video frames




(b) corresponding optical flow (*)

Avendo un sensore con elevati FPS (>30) e risoluzione è possibile verificare

- 1) Assenza di pattern da effetto Moirè $\rightarrow$ non abbiamo un video
- 2) Movimento delle palpebre compatibile per direzione ed entità a quello naturale

(*) Lo scopo del flusso ottico è quello di assegnare ad ogni pixel appartenente al frame corrente un motion vector che punta verso la posizione dello stesso pixel in un frame di riferimento successivo.

Attacco e difesa della rilevazione del battito di palpebre



Un attacco con maschera con ritagli per mostrare gli occhi vivi
viene identificato lo stesso delle deformazioni del flusso ottico
causate dalla discontinuità dei fori fra
le parti mobili (occhi) e fisse (maschera)

Anti-spoofing by remote photoplethysmography



✓ Real Face




✗ Prints Attack



✗ Replay Attack



✗ 3D Mask Attack




Anti-spoofing by rPPG in realtime: Server Intel


- Intel ha realizzato nel 2022 la prima piattaforma online per la detezione dei deepfake
- Il cuore del sistema è FakeCatcher (rPPG) + eye gaze detection (Intel Xeon Scalable Processor, OpenVINO™ toolkit)


<https://www.intel.com/content/www/us/en/research/blogs/trusted-media.html>

Intel Optimized Stack for Media Analytics



Create flexible solution ranging throughput, latency and dense solutions through intel® architecture portfolio






Fabio Scotti - Università degli Studi di Milano

Il 3D come antispoofing


Sensori-webcam 3D, laptop e cellulari




RealSense R200



Apple Iphone X Face ID





RealSense D435



Integrato nei laptop

D435 immagini [ripasso]



Tecnologia Intel RealSense

Permette di rilevare congruenza fra 2D e 3D della scena rilevata




D435




Color Image



Depth Image



How Face ID Works




Esempio Facelid Apple

Sistema a luce strutturata per 3D (30.000 punti)



Spoofing IR (3D) + Visibile → Apple Face ID




Face ID

Bkav Corporation:
A leading firm in network security,
software, smartphone manufacturing
and smarthome.


Ulteriori miglioramenti alla biometria del volto

- Avevamo indicato fra i principali fattori migliorativi della biometria del volto
 - alta risoluzione delle immagini
 - multiple stills (frame multipli)
 - Introduzione dei dati tridimensionali
- Vediamo ora un esempio di sistema commerciale particolarmente significativo che riassume tutti questi aspetti




Controllo del volto 3D usando un sistema 2D

- Partendo dal sensore più semplice ovvero la camera visibile 2D
- → è possibile eseguire shape from motion




Controllo del volto 3D usando un sistema 2D

- Le caso del volto ecco un esempio possibile di **shape from motion**




Ulteriori possibili controlli: spettrometria e termografia del volto

- Usando illuminatori a frequenze ottiche diverse è possibile avere in tempo reale una spettrografia del volto
- Attraverso dei sistemi di classificazione che analizzano lo spettrogramma si stima il materiale di cui è composto
- Questo permette di controllare se è di tipo organico o plastico, se contiene acqua, grassi, pigmenti, gomma, silicone, ecc.
- Anche una immagine termografica permette di capire se abbiamo di fronte tessuti a temperatura corretta!



Approfondimento (non richiesto all'esame)


- <https://www.spoofbounty.com/>
- Demo della tecnologia antispoofing ZoOM
<https://www.youtube.com/watch?v=MEPgs7ovb-g&authuser=0>
- Demo della tecnologia BioID di face liveness
<https://youtu.be/14ivZ9shtmY>




Produzione Fake + Attacco a Response-Challenge: 3D Face Tracking and Texture Fusion in the Wild

Esempio di approccio
real-time per alterare
pose ed espressioni
in attacchi

Frames of a 2D video



3D Morphable
Face Model



Frontalisation and novel poses with
arbitrary expressions

SECURITY CERTIFIED
#1 IN THE WORLD



FaceTech

Esempi di soluzioni commerciali

Controllo del volto 3D usando un sistema 2D

- Es: ZoOm (Facetech) → avvicinare il telefono
- Non serve per forza ruotare la testa per ricostruire ear2ear → è la zona centrale del volto ha maggiori dettagli 3D utili



NORMAL, NO DISTORTION



FISH-EYE, PERSPECTIVE DISTORTION





- “ZoOm’s 3D FaceMaps are created with standard 2D cameras, but contain much more data than a flattened photo ever can”
- “ZoOm utilizes the same ubiquitous camera hardware to outperform 2D face matching in every way”

Affermazioni del produttore –
No test indipendenti


Tecnologia offerta da Facetech

3D FaceMap

- Con 1 video da 2s sono possibili 3 risultati
- Verifica Liveness
- 3D della superficie



VERIFIES
LIVENESS



VERIFIES
3-DIMENSIONALITY



VERIFIES
IDENTITY

Antispoofing FaceTech

- We have performed hundreds-of-millions of spoof attempts with every conceivable type of media and learned how to stop them
- 2D paper photos & digital images
- High resolution videos
- Image swap-in after liveness check
- Paper masks with eye & mouth cutouts
- Hollywood masks, wax figures & lifelike dolls
- Photos or video frames animated into avatars
- Video projections on 3D heads
- Sleeping users with closed eyes
- Impostors, lookalikes & doppelgangers


Antispoofing FaceTech

- Filmato della demo sul test di liveness

- (<https://youtu.be/MEPGs7ovb-g>)


Non certificato per questo tipo di attacchi
(Level 3)

Custom-made ultra-realistic 3D masks, wax heads, etc., up to \$3,000 in creation cost. *No Lab Testing Avail



Confronto fra 2D, 3D, FaceTec

ATT! Fornito dal produttore



TYPE	2D	3D	FaceTec® 3D
Liveness Testing Certifications	No 3rd Party Certs	No 3rd Party Certs	Certified Level 1 & 2 Spoof Detection by iBeta/NIST - Liveness.com
Liveness Strength	Fairly Weak	Fairly Strong	Strong
3D Depth Detection	Weak	Strong	Strong
Liveness Method	Challenge/Response, Blink, Smile, Turn Head or Flashing	Infrared dots + neural network chip determine if user is 3D	Measures 3D Depth, skin texture, eye reflections, etc.

Antispoofing Livelli ISO



<https://www.iso.org/standard/67381.html>

ZoOM is passing
NIST/NVLAP Lab
Level 1 & 2 PAD
testing with
0% FAR

PAD =
Presentation Attack Detection

Artifact Level	Description	Example
Level 1 (A) (Spoof Bounty Avail)	Hi-res paper & digital photos, hi-def challenge/response videos and paper masks. Beware: iBeta Lab Tests DO NOT include digital deepfake puppets, but FaceTec's Spoof Bounty DOES include deepfake puppets.	
Level 2 (B) (Spoof Bounty Avail)	Commercially available lifelike dolls, and human-worn resin, latex & silicone 3D masks under \$300 in price.	
Level 3 (C) (Spoof Bounty Avail)	Custom-made ultra-realistic 3D masks, wax heads, etc., up to \$3,000 in creation cost. *No Lab Testing Avail	

BioID

Esempi di soluzioni commerciali

Soluzione BioID

- BioID GmbH è una società tedesca attiva da 20 anni specializzata in:
 - autenticazione biometrica
 - face recognition
 - liveness detection (PAD)
 - onboarding remoto / eKYC (electronic Know Your Customer)
- La società BioID offre un sistema di liveness e riconoscimento facciale 3D da cellulare con sensore 2D (BioID Web Service)
 - (Primo patent 2004, vedi LIPS+Voce prossima lezione)
- Lavora con camera di diverso produttore e formato
- **GDPR compliant technology** (meglio verificare su quali aspetti...)
- La società dichiara che è basato su
 - Flusso ottico
 - Analisi delle texture via AI
 - CNN allenate con moltissimi esempi di attacchi e volti reali

BioID liveness-detection

<https://www.bioid.com/liveness-detection/>

1



3D Object Validation

By capturing only two images using any standard camera, BioID's unique motion-analysis algorithm validates whether the face detected is indeed from a real person.

2



AI Technology

Powerful DNNs (deep neural networks) are used to detect presentation attacks like 3D masks, video replays, projections, etc.

3



Deepfake Check



Sophisticated algorithms are incorporated to reject images/videos that have been manipulated using deepfake tools.

4



Challenge-Response

Optional patented user interaction to obtain 'user consent' during the video liveness check.



BioID level 3 ISO 30107

il sistema utilizza un modulo di **Presentation Attack Detection (PAD)** conforme alla ISO/IEC 30107, capace di rilevare attacchi con maschere in silicone tramite liveness **passiva**, senza hardware dedicato.

<https://www.youtube.com/watch?v=R-ySuJ-KiAQ>



Abbiamo visto

- Adversarial Attacks Detection
 - Evasione
 - Avvelenamento
 - Estrazione
 - Inferenza
- Vulnerabilità dei sistemi biometrici
 - Presentation Attacks (PA)
 - Presentation Attack Detection (PAD)
 - Tecnologie generali di Anti-Spoofing
 - Flusso ottico
 - Liveness
- Spoof./AntiS. Face
 - 2D
 - 3D



FISH-EYE, PERSPECTIVE DISTORTION

